Bases de Datos a Gran Escala

Sesión 0 · Introducción

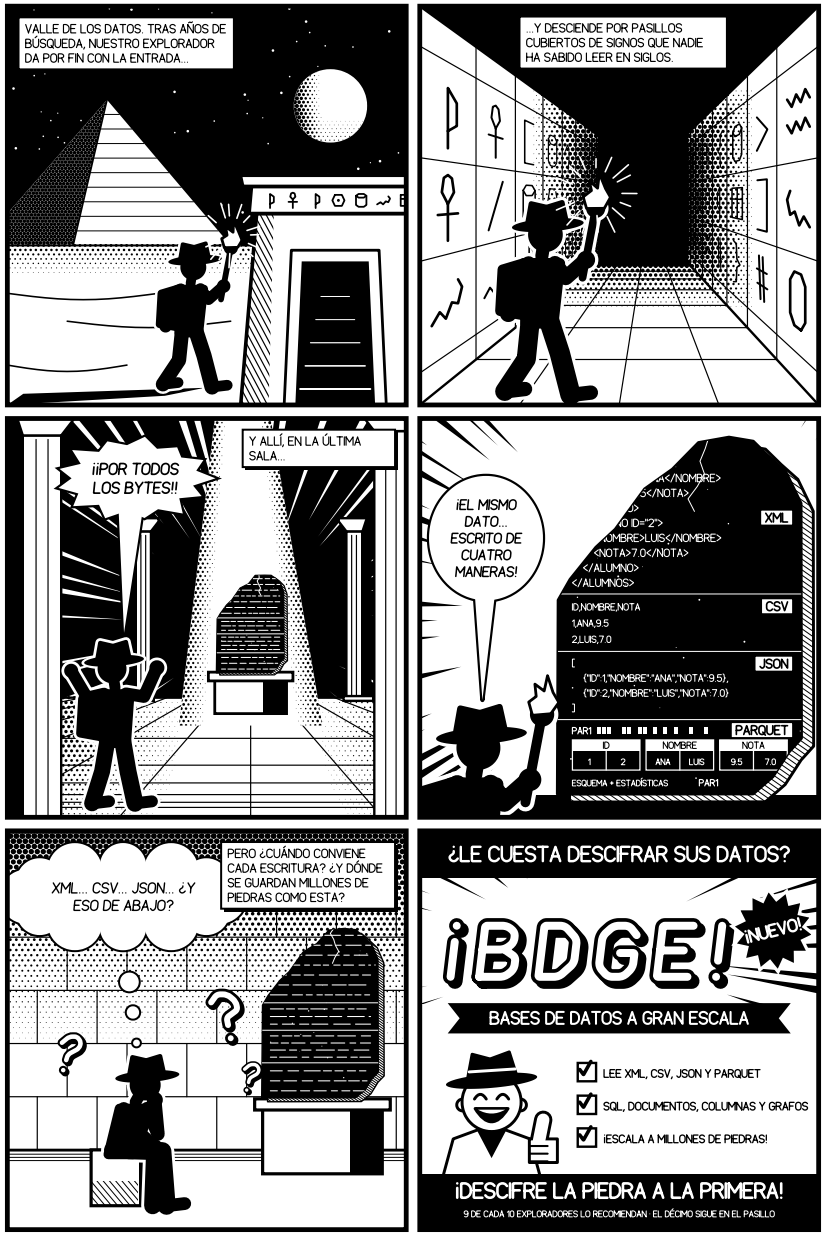
Curso 2026/2027

Diego Sevilla Ruiz
Departamento de Ingeniería y Tecnología de Computadores
Facultad de Informática · Universidad de Murcia

dsevilla@um.es


BDGE
BASES DE DATOS A GRAN ESCALA
III

LA PIEDRA DE LOS DATOS



Bases de Datos a Gran Escala

Curso académico	2026/2027
Titulación	Máster en Big Data
Cuatrimestre	Primero
Curso	Primero
Carácter	Obligatoria
Créditos ECTS	4,5
Departamento	Ingeniería y Tecnología de Computadores

Profesor y horario

Actividad	Profesor	Horario	Aula
Teoría	Diego Sevilla	Miércoles, 16:00–18:00	Lab. 2.4
Prácticas	Diego Sevilla	Jueves, 16:00–17:30	Lab. 2.4

Tutorías y contacto

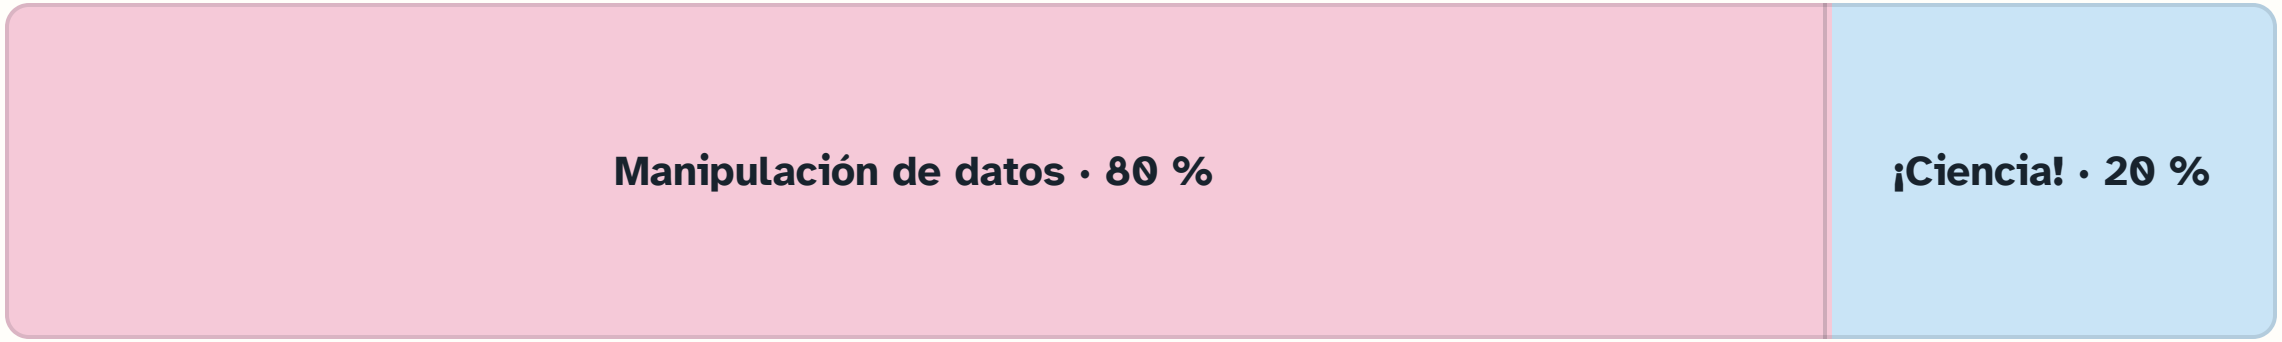
Tutorías	Contacto
Jueves, 11:00–14:00 y tutorías electrónicas	`dsevilla@um.es` 868 88 7571 Despacho 3.31

Introducción a la asignatura

Tópicos

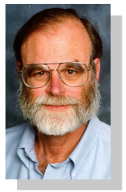
- Modelado de datos SQL, NoSQL y NewSQL
- Lenguajes de consulta de datos
- Introducción a los *data lakes*
- Uso de bases de datos clave/valor, documentales, columnares y de grafos
- Formatos de intercambio de datos —CSV, XML, JSON, Parquet y Avro — y particionamiento
- Dimensionamiento correcto de las soluciones de tratamiento de datos

Data Science



La mayor parte del trabajo está en **obtener, limpiar, organizar, transformar y consultar** los datos

Data Access Hitting a Wall



Current practice based on data download (FTP/GREP)
Will not scale to the datasets of tomorrow

- You can GREP 1 MB in a second
- You can GREP 1 GB in a minute
- You can GREP 1 TB in 2 days
- You can GREP 1 PB in 3 years.

- Oh!, and 1PB ~5,000 disks

- At some point you need
  indices to limit search
  parallel data search and analysis
- This is where databases can help

- You can FTP 1 MB in 1 sec
- You can FTP 1 GB / min (~1$)
- … 2 days and 1K$
- … 3 years and 1M$



[slide src: Jim Gray]

Data Science

- Se pasa un **80–90 %** del tiempo importando datos, organizándolos y optimizando su tratamiento
- Estudiaremos las **abstracciones del modelado de datos** y las herramientas disponibles: las **bases de datos**
  - ¿Cómo se organizan y modelan los datos?
  - ¿Cómo se consultan de forma eficiente?
  - ¿Cómo se tratan los datos heterogéneos?
  - ¿Cómo se gestionan cantidades de datos que no caben en una máquina (*big data*)?
  - Modelado relacional, índices, desnormalización, duplicación y agregación
- Estudiaremos modelado de datos SQL, NoSQL y NewSQL

> «...no greater barrier to effective data management will exist than the variety of incompatible data formats, non-aligned data structures, and inconsistent data semantics.»
> — Doug Laney, *3-D Data Management: Controlling Data Volume, Velocity and Variety*, Gartner, 2001

eScience, Data Science y el cuarto paradigma

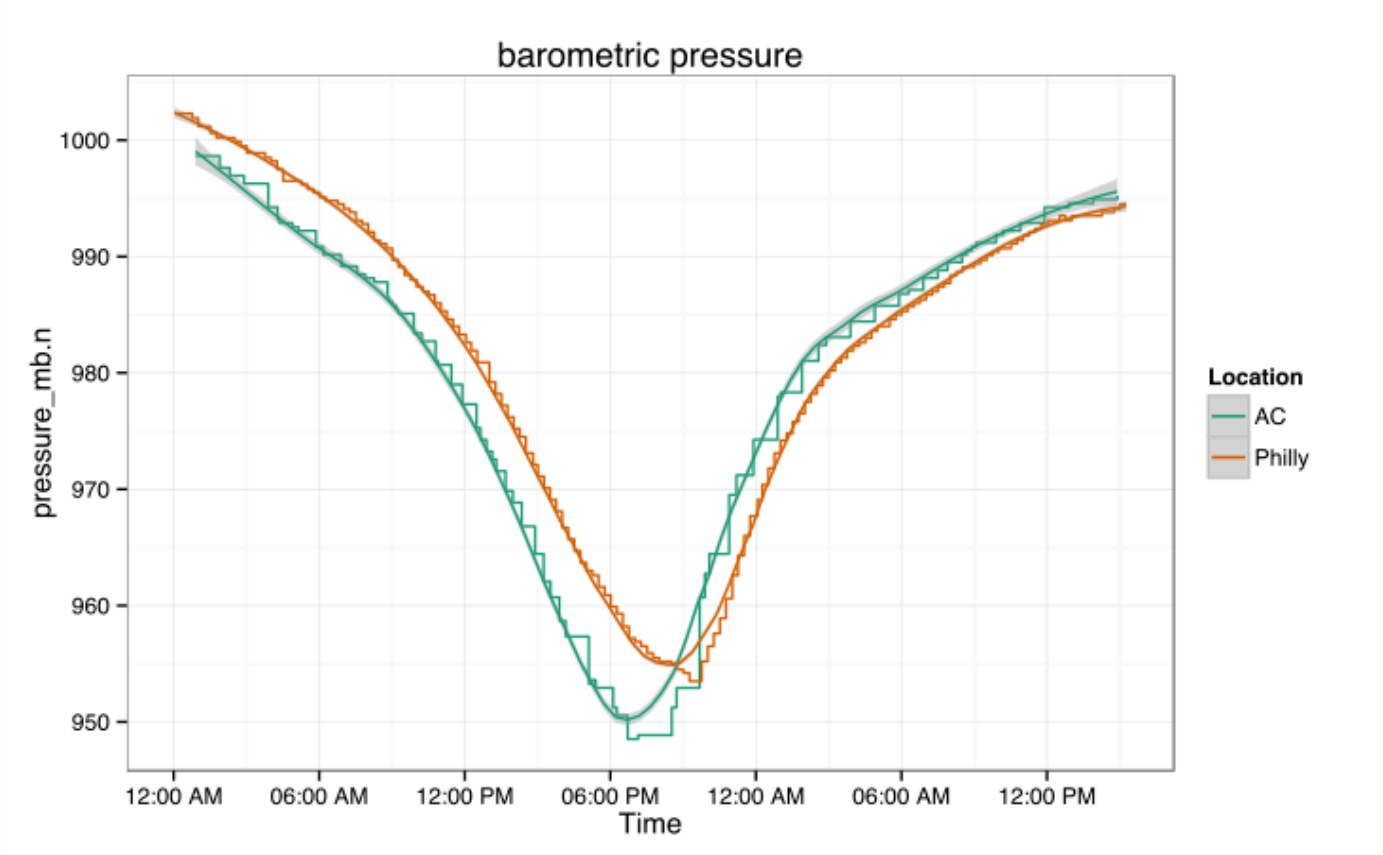
- Tradicionalmente, la ciencia se desarrollaba de forma **empírica**, por observación o reproduciendo condiciones en el laboratorio
- Desde hace unos cientos de años, los **modelos teóricos** se aceptan también como una forma de explicar sucesos y sugerir nuevos experimentos
- En los últimos ~50 años, la **simulación** permite reproducir condiciones especiales o no reproducibles. Para modelos demasiado complejos para resolverlos analíticamente, se parte de un estado inicial y se estudia su evolución

Cuarto paradigma

- Hoy: **exploración basada en datos**
  - Unifica teoría, experimentación y simulación
  - Los datos se capturan por instrumentos o se generan por simulaciones
  - Son procesados por software; la información y el conocimiento extraído se almacenan en ordenadores
  - Los científicos analizan ficheros y bases de datos con nuevas herramientas estadísticas y de datos, capaces de gestionar cada vez más volumen
  - En vez de «**preguntar al mundo**», se combinan conjuntos de datos «**descargados**» de formas antes no previstas
- **Jim Gray**, *The Fourth Paradigm*, Microsoft Research, 2009

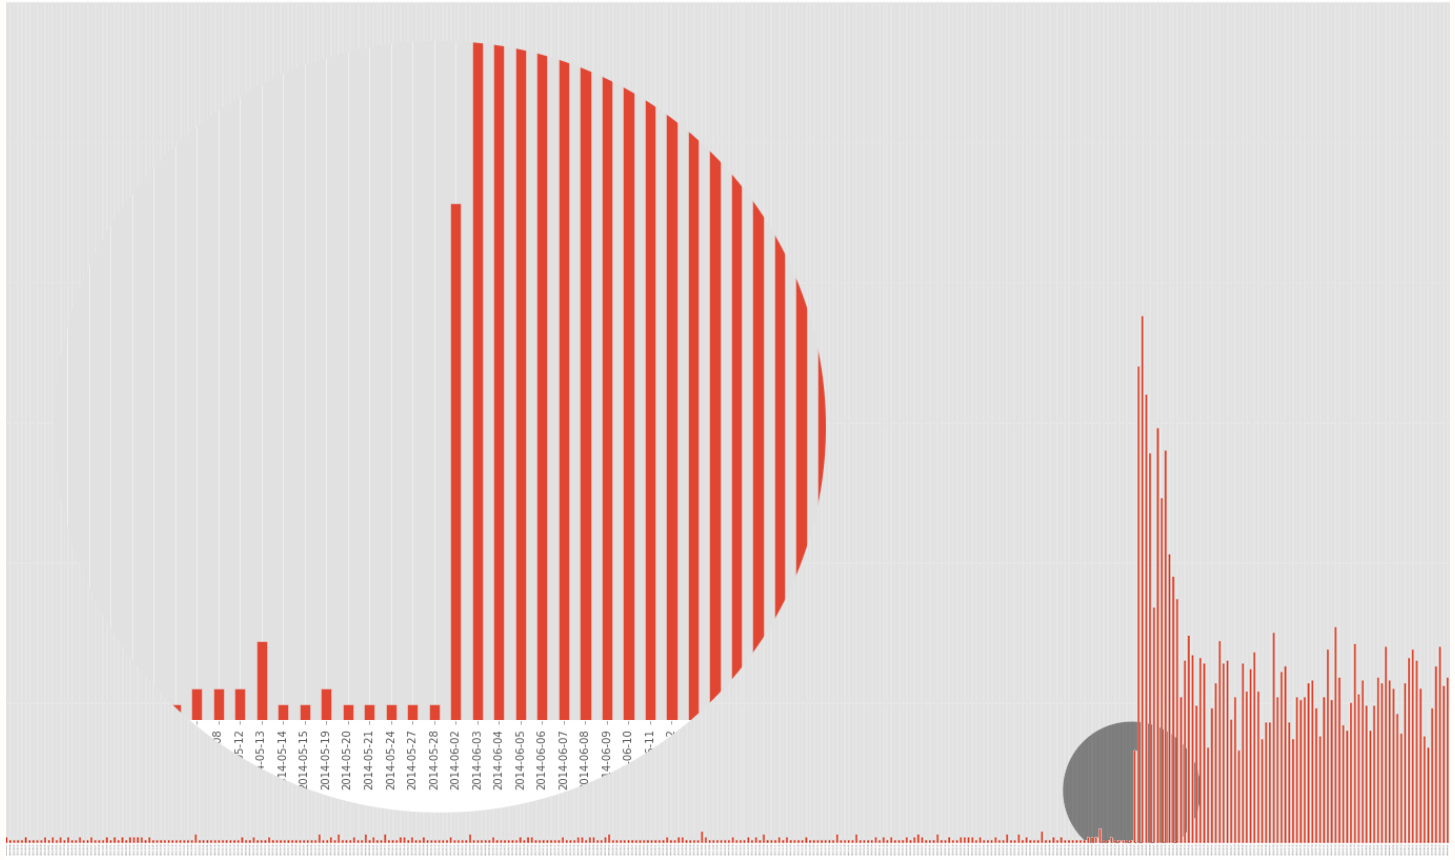
Huracán Sandy, 2012

https://rpubs.com/JoFrhwld/sandy · Howe, 2013

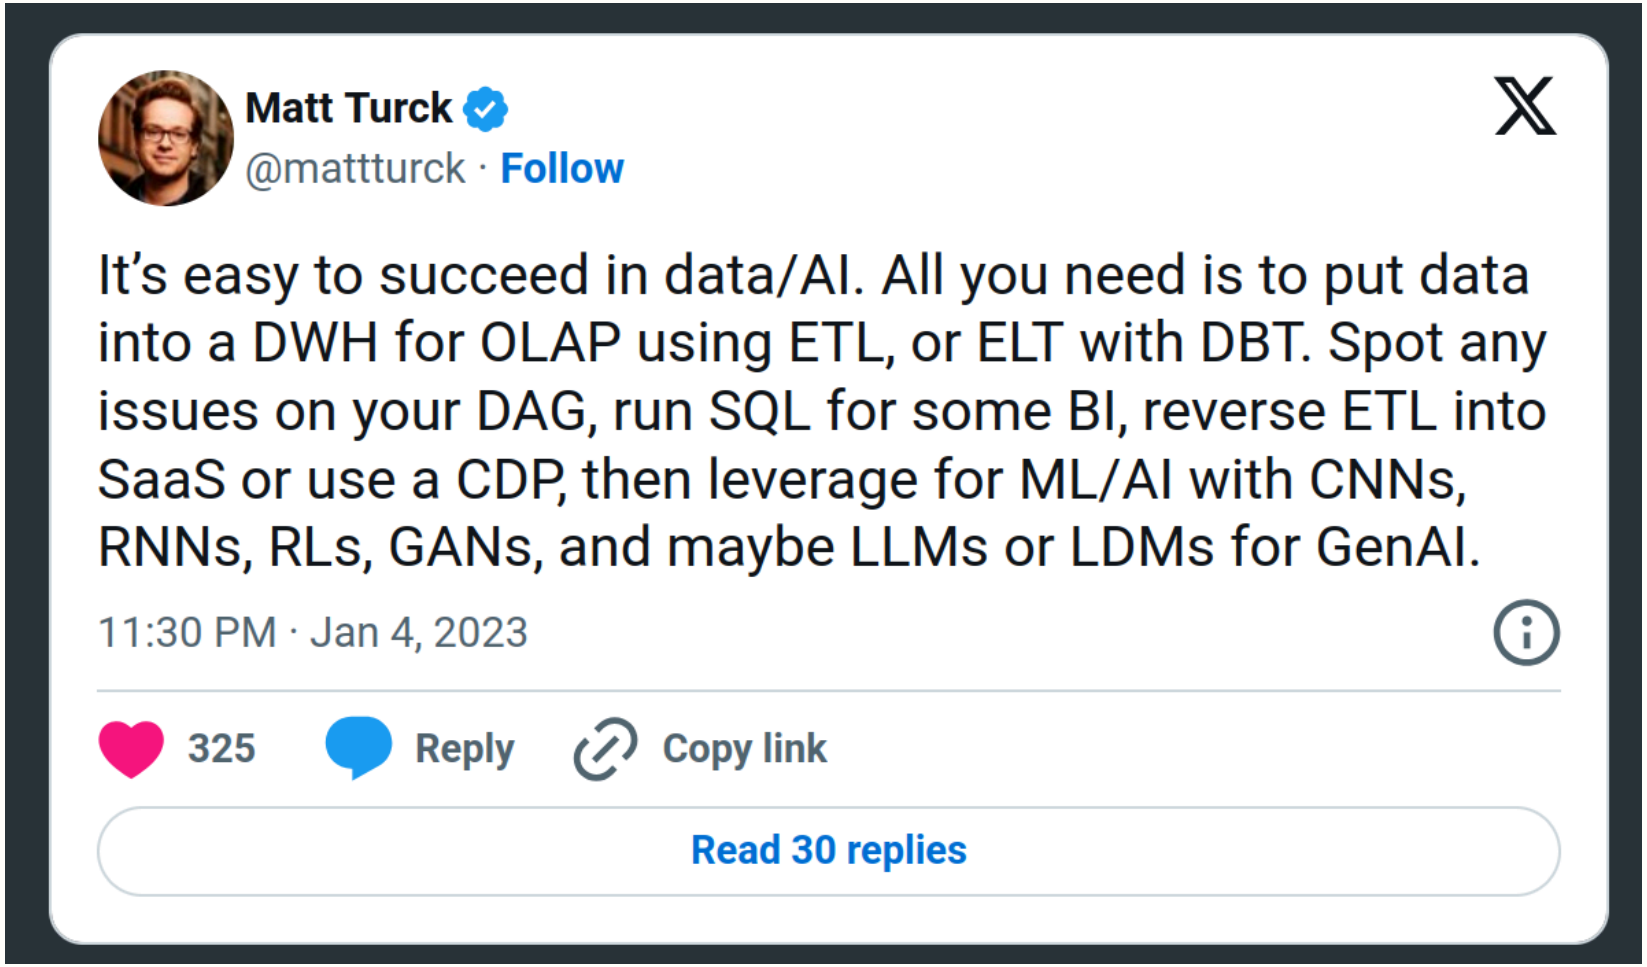


¿Cuándo introdujo Apple «Swift»?

Una mirada al tag `swift` de todas las preguntas de Stack Overflow



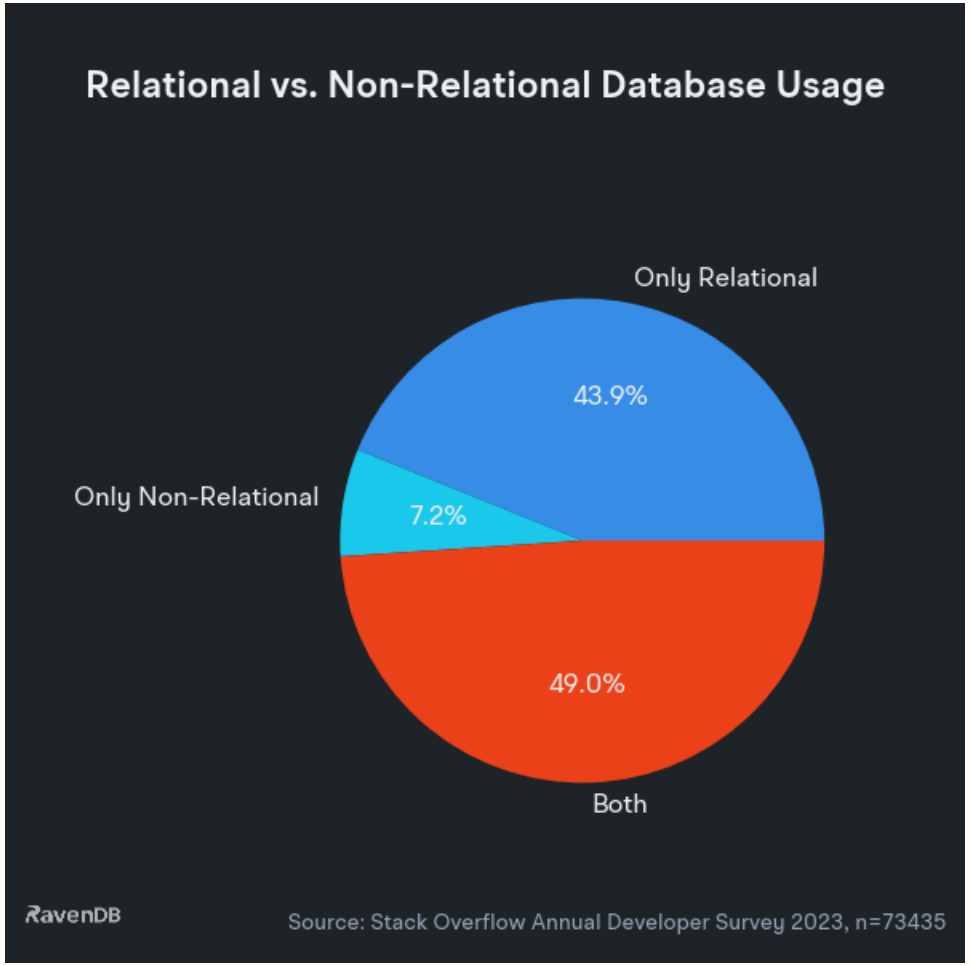
¿Bases de datos hoy?



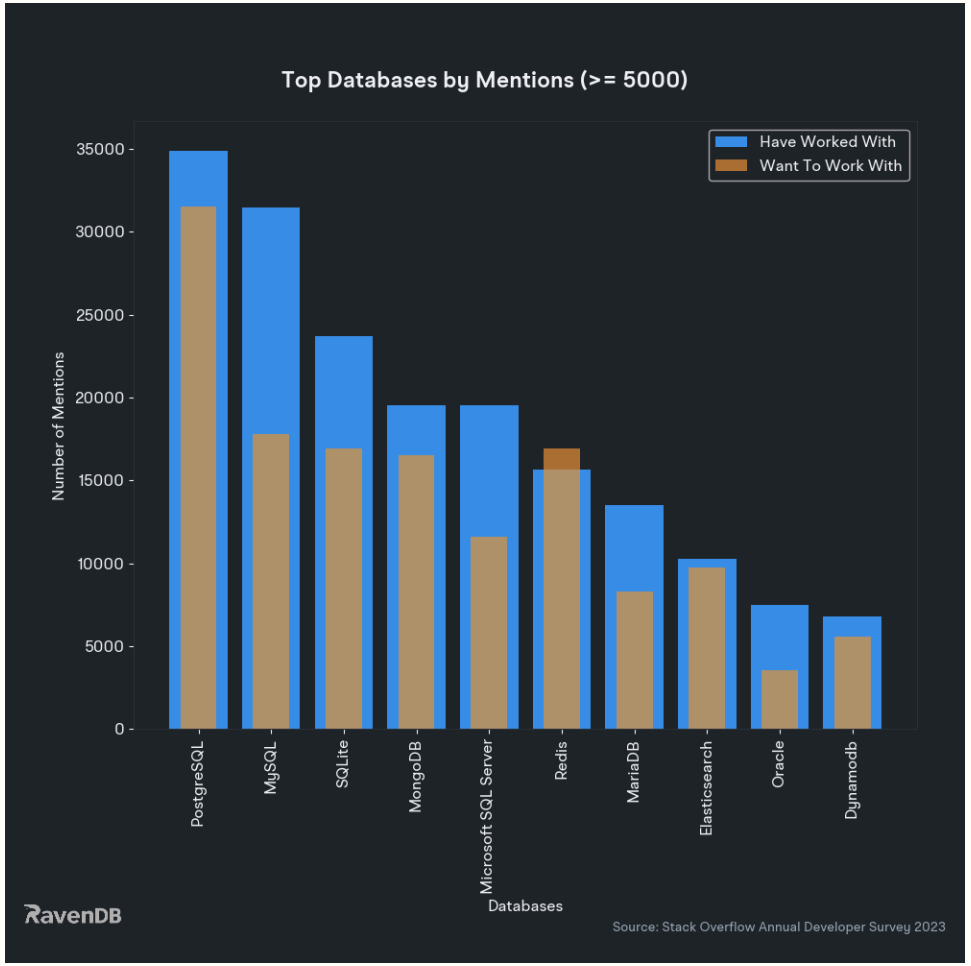
¿Bases de datos hoy?

- No hay fuentes fiables que muestren el uso real de las bases de datos
- Referencias útiles:
  - DB-Engines Ranking
  - 2024 NoSQL Database Trend Report, basado en el JetBrains 2023 Developer Ecosystem
  - Stack Overflow Developer Survey 2025
  - JetBrains 2024 Developer Ecosystem: Databases
  - Encuesta DeveloperWeek 2019, con más de 8 000 desarrolladores

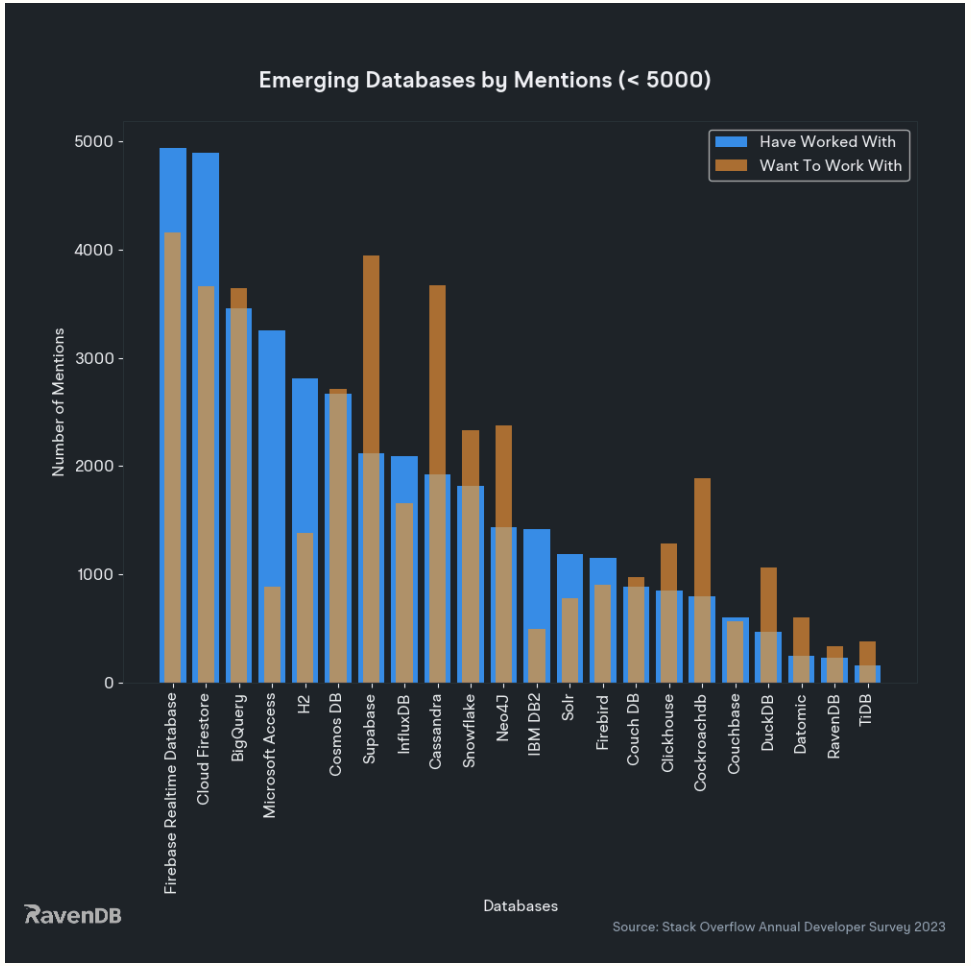
SQL, NoSQL y persistencia políglota



Bases de datos más populares

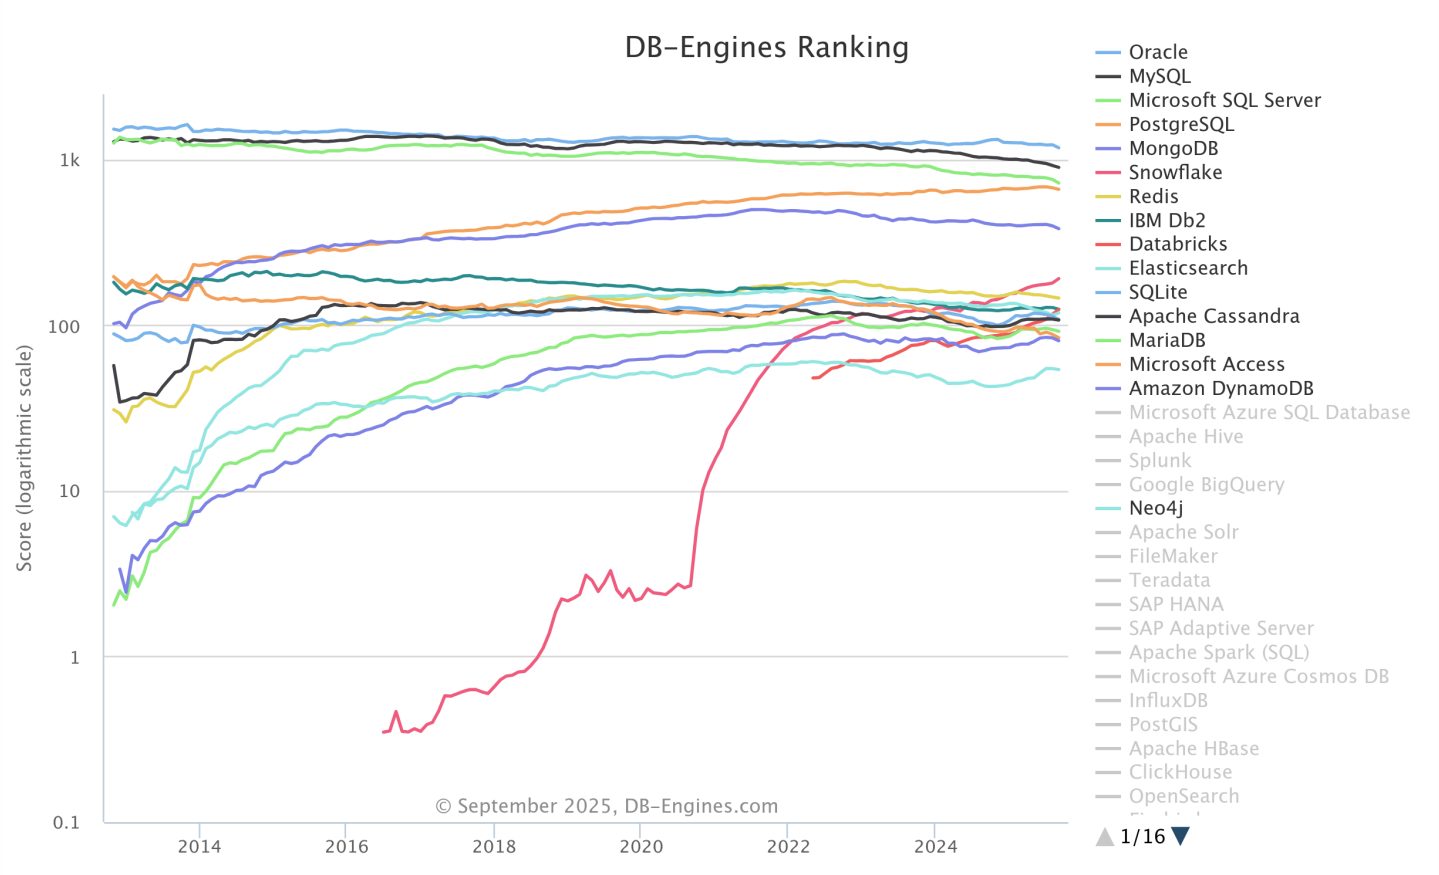


Bases de datos emergentes



Comparación con DB-Engines

https://db-engines.com/en/ranking



Bases de datos usadas en el último año

JetBrains, 2024



	2019	2020	2021	2022	2023	2024
MySQL	60%	59%	61%	52%	51%	52%
PostgreSQL	32%	35%	36%	38%	38%	45%
MongoDB	30%	32%	28%	27%	27%	30%
SQLite	29%	27%	29%	28%	25%	30%
Redis	27%	25%	29%	27%	26%	29%
Microsoft SQL Server	22%	20%	19%	18%	18%	20%
MariaDB	21%	19%	23%	18%	16%	16%
Elasticsearch	–	–	–	–	–	13%
Oracle Database	16%	14%	13%	11%	13%	12%
Amazon DynamoDB	–	–	–	–	–	10%
H2	7%	6%	5%	6%	6%	6%
BigQuery	–	–	–	–	–	5%
Cloud Firestore	–	–	–	–	–	5%
Amazon Athena	–	–	–	–	–	3%
ClickHouse	1%	1%	2%	2%	3%	3%
Snowflake	–	–	–	–	–	3%
Amazon Redshift	5%	4%	3%	3%	4%	3%
Cassandra	4%	3%	3%	3%	3%	3%
Db2	3%	3%	2%	2%	3%	2%
Neo4j	2%	2%	2%	2%	2%	2%
HBase	3%	2%	2%	1%	1%	2%
CockroachDB	–	–	–	–	–	1%
Couchbase	1%	1%	1%	1%	1%	1%
Presto	–	–	–	–	–	1%
Other	7%	7%	7%	8%	7%	4%
None	7%	8%	8%	9%	11%	8%

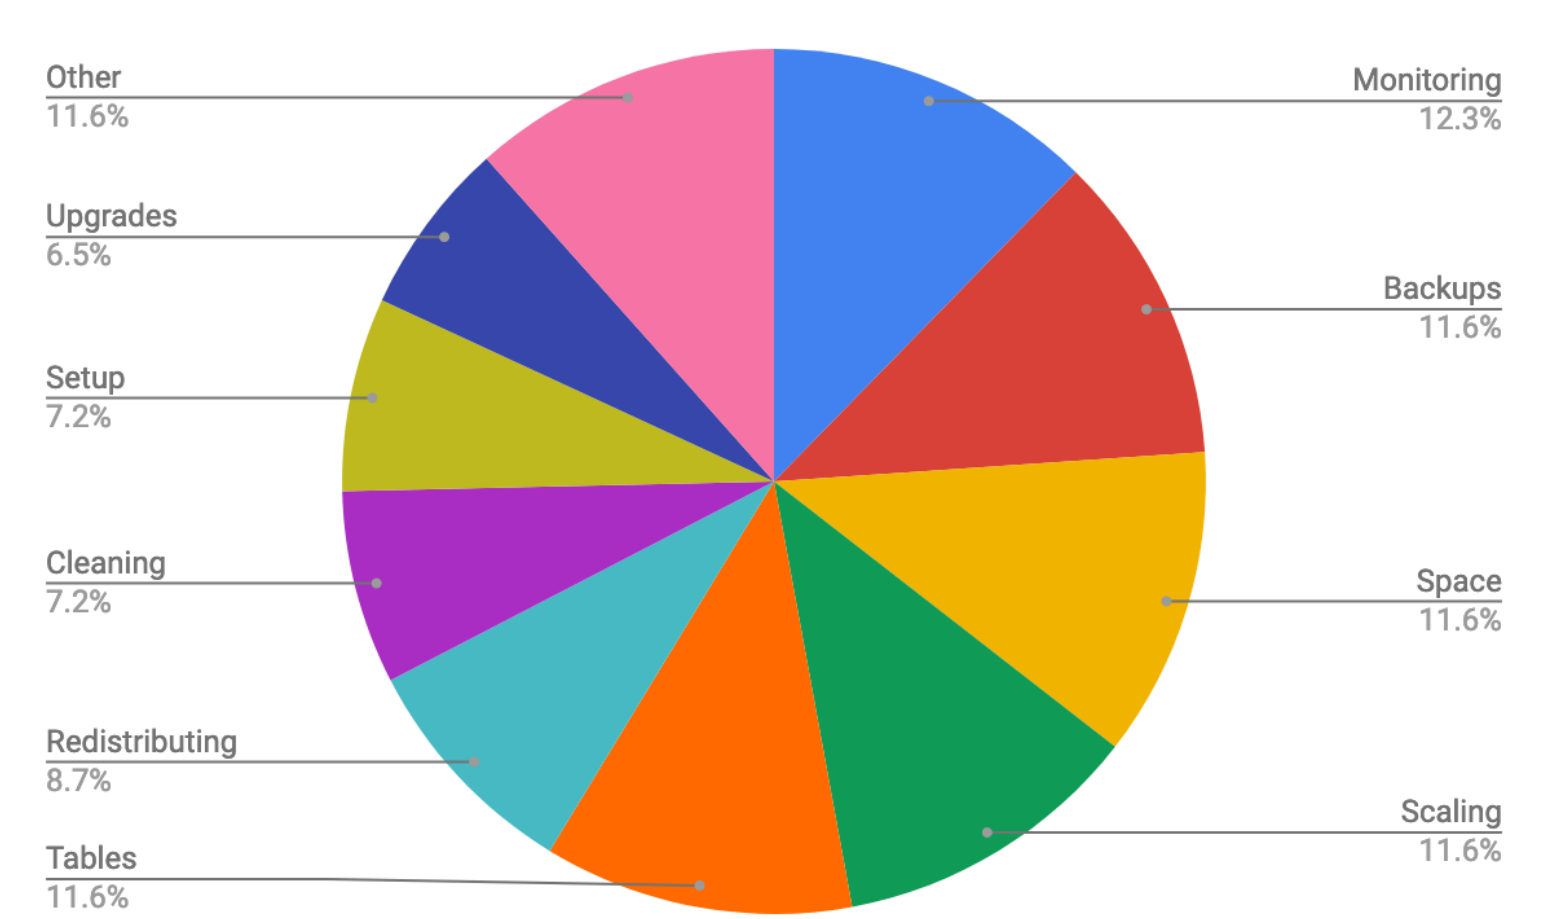
Reciprocidad entre bases de datos

Alta en combinaciones SQL + NoSQL

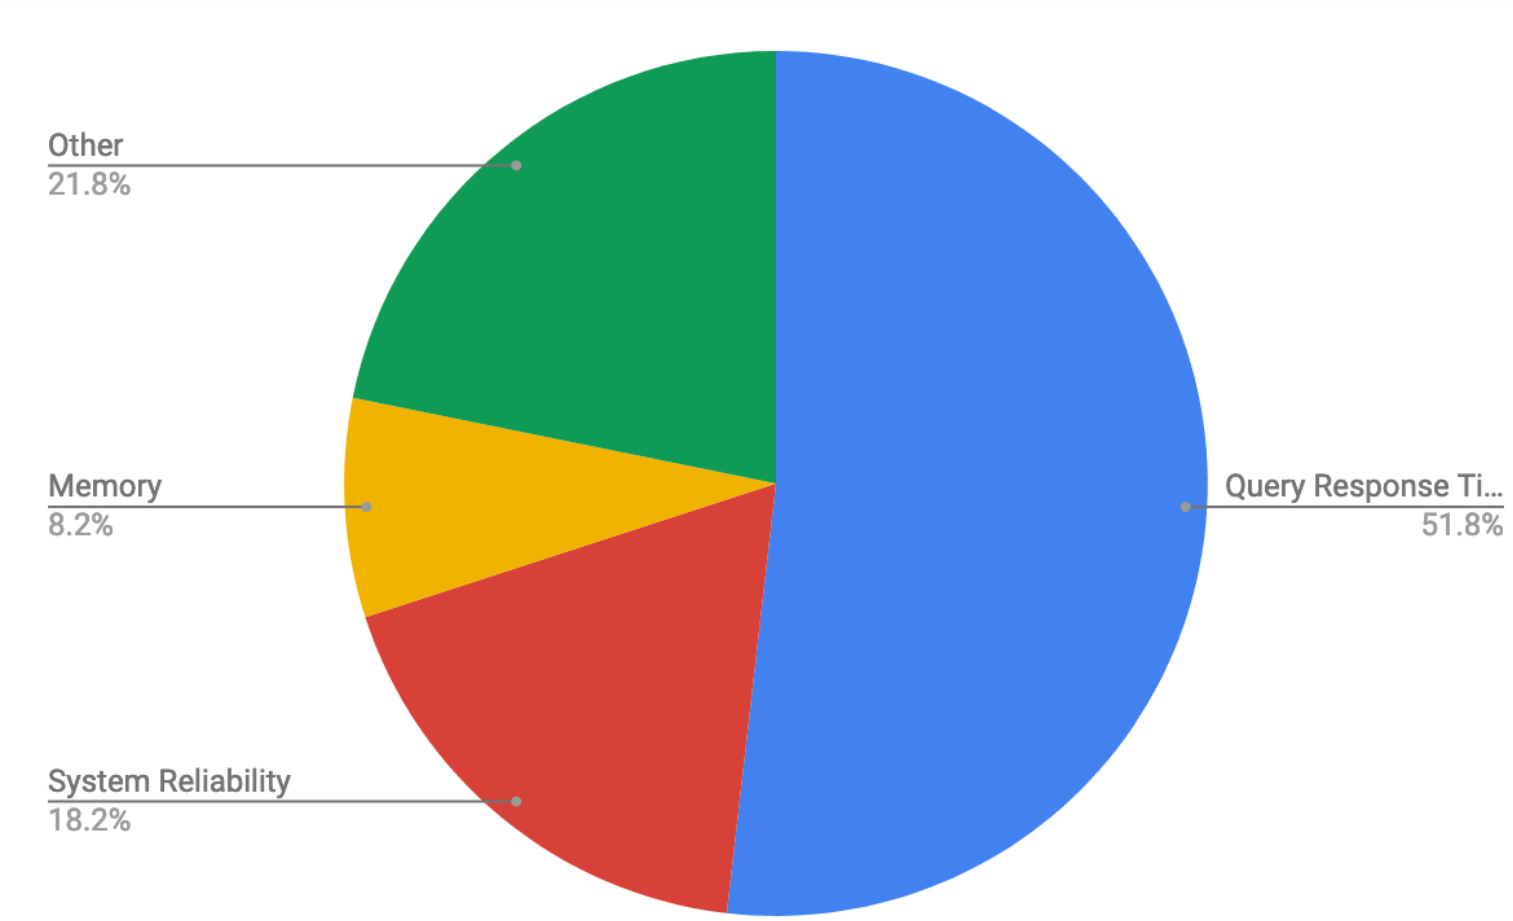
	MySQL	PostgreSQL	MongoDB	Redis	SQLite	MS SQL Server	MariaDB	Oracle Database
MySQL	–	51%	64%	69%	59%	53%	75%	58%
PostgreSQL	38%	–	50%	55%	51%	39%	50%	40%
MongoDB	33%	35%	–	40%	32%	31%	37%	29%
Redis	35%	37%	39%	–	34%	22%	38%	29%
SQLite	29%	33%	30%	32%	–	28%	38%	21%
MS SQL Server	18%	18%	21%	15%	20%	–	20%	29%
MariaDB	23%	20%	22%	23%	24%	18%	–	16%
Oracle Database	14%	13%	14%	14%	11%	21%	13%	–
DB2	3%	3%	3%	3%	2%	4%	3%	6%
Cassandra	3%	4%	5%	5%	2%	3%	3%	4%
Couchbase	1%	1%	1%	1%	1%	1%	1%	2%
HBase	2%	2%	2%	4%	2%	2%	2%	3%
Neo4j	3%	3%	4%	4%	3%	2%	3%	3%
Amazon Redshift	3%	5%	5%	4%	3%	5%	4%	6%
H2	7%	9%	8%	9%	6%	6%	10%	12%
ClickHouse	3%	4%	3%	6%	2%	2%	3%	3%
Other	5%	8%	6%	7%	6%	7%	6%	6%

0 75%

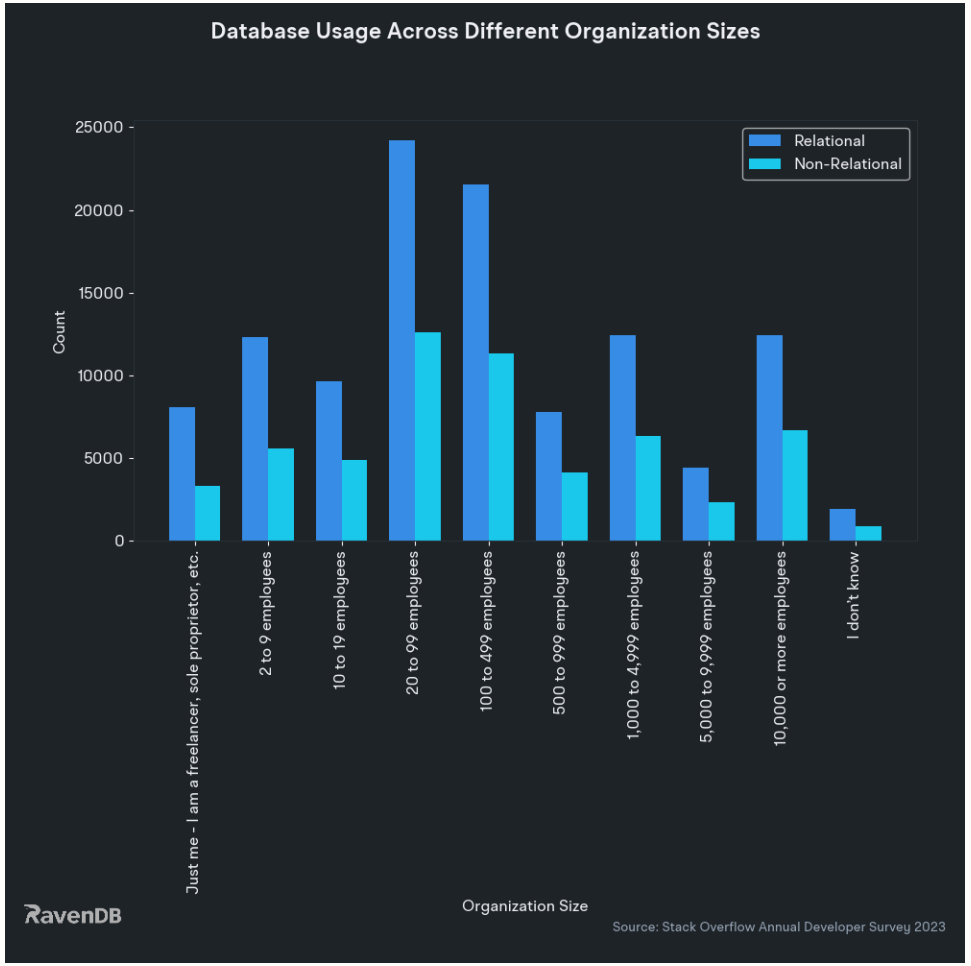
Tareas que más consumen tiempo



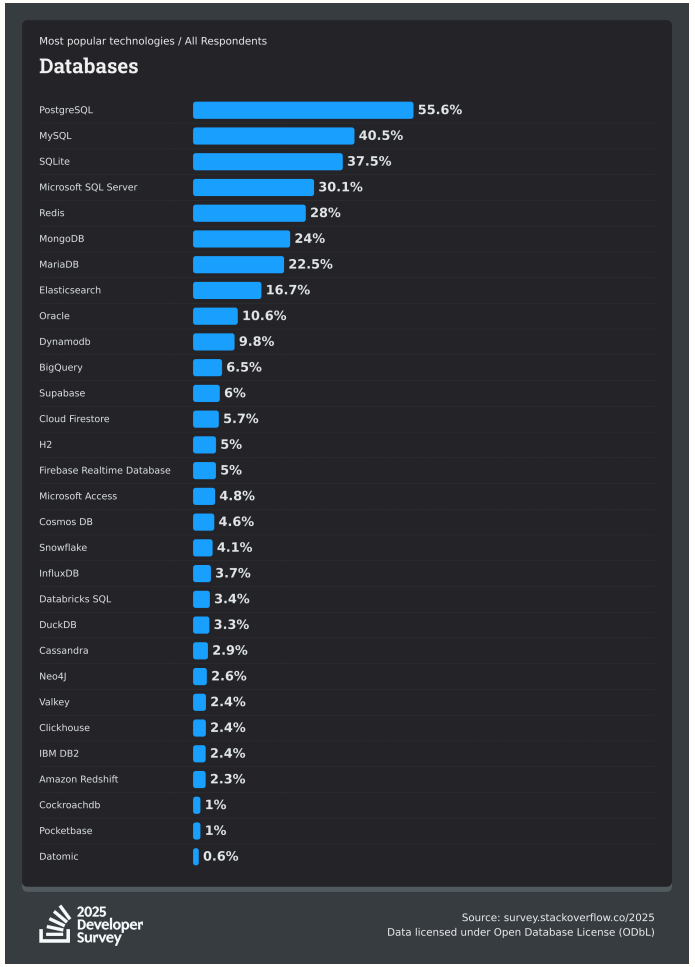
Métricas más importantes en bases de datos



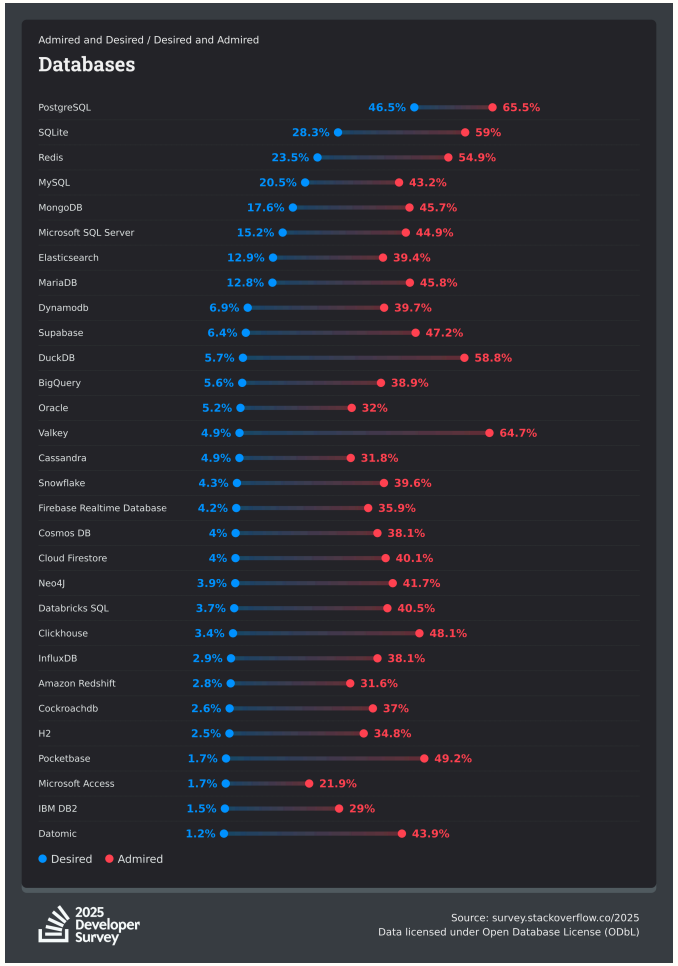
Uso de bases de datos según el tamaño de la empresa



Stack Overflow: uso de bases de datos



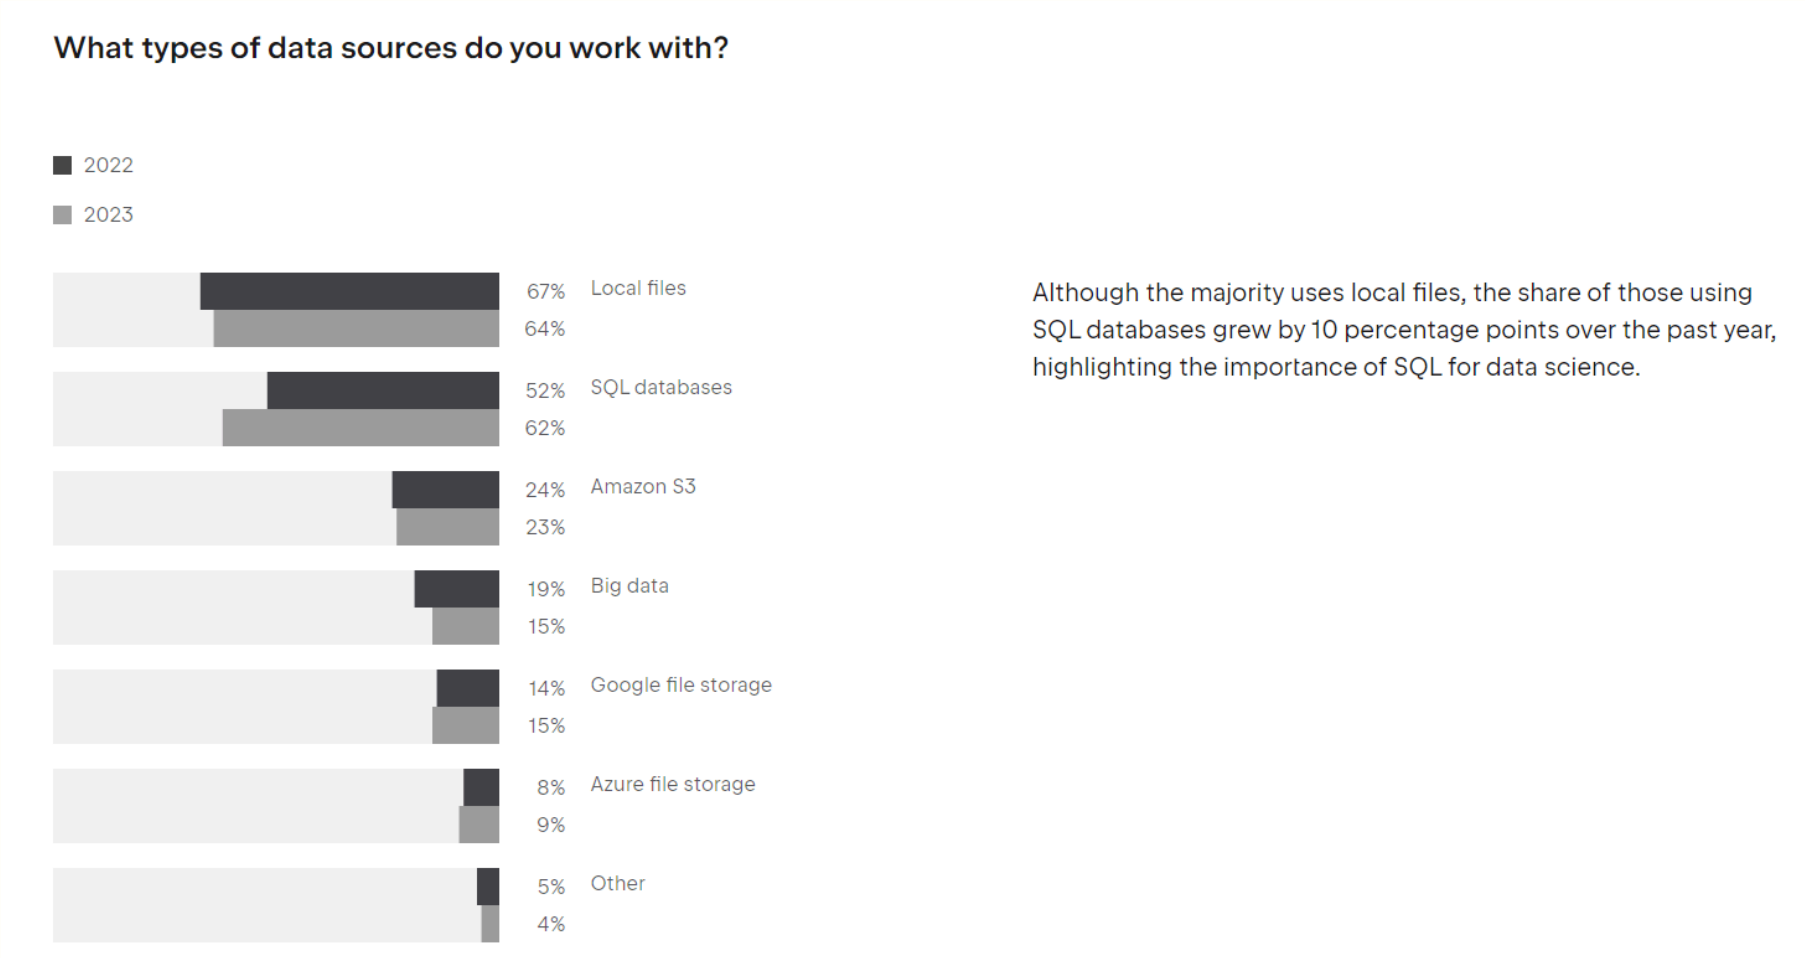
Stack Overflow: bases de datos queridas y admiradas



Resumen

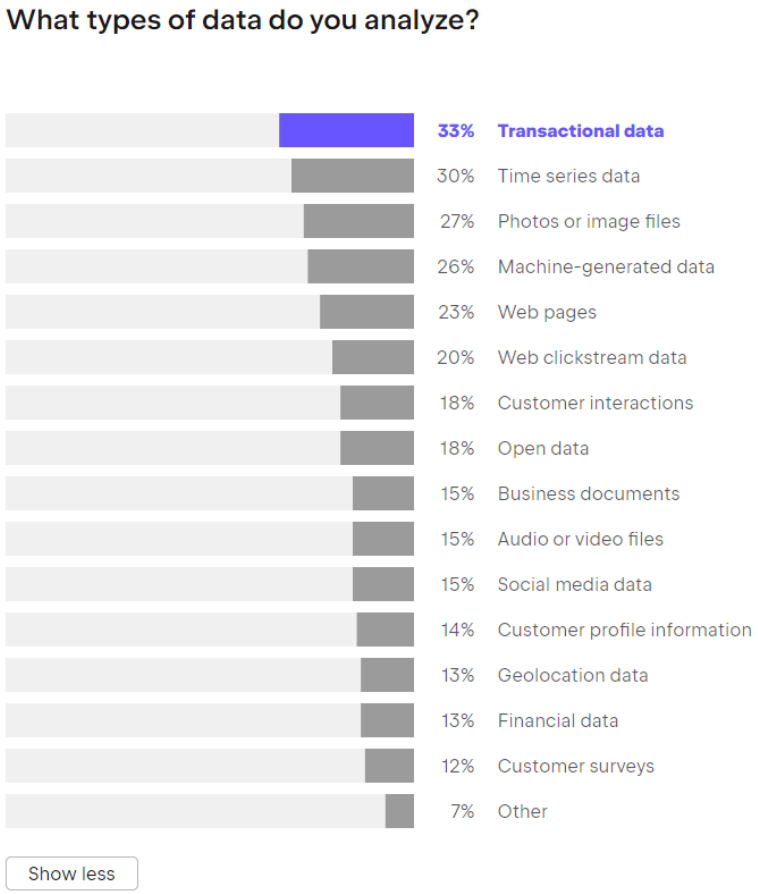
- Las bases de datos relacionales no van a desaparecer, aunque no sean las favoritas de los desarrolladores: casi la mitad combina SGBDR y NoSQL
- NoSQL se adopta para roles especializados: Redis y MongoDB muestran una alta reciprocidad con las bases de datos relacionales
- La IA y el *machine learning* impulsarán la demanda de datos
- Aumentan las nubes especializadas y los datos gestionados
- NoSQL se usará cada vez más con sistemas distribuidos

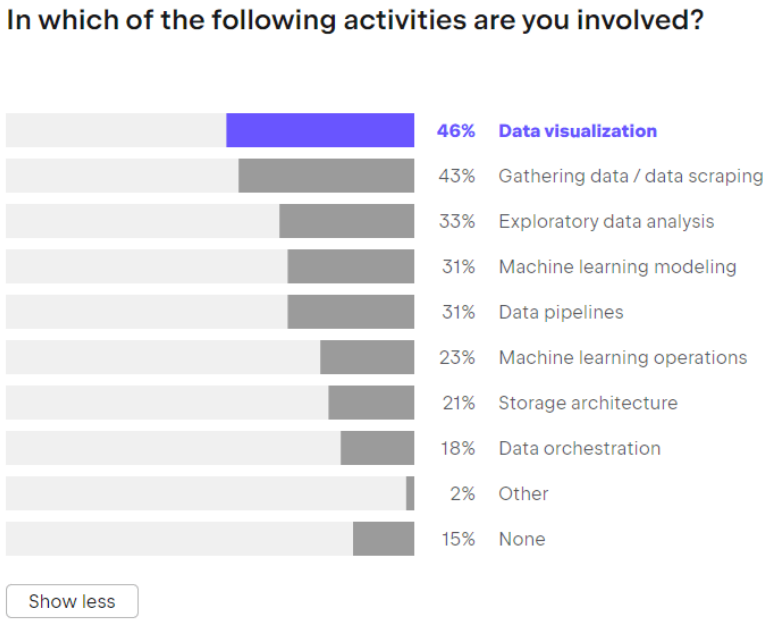
Fuentes de datos para proceso



Although the majority uses local files, the share of those using SQL databases grew by 10 percentage points over the past year, highlighting the importance of SQL for data science.

Tipos de proceso de datos





Planificación del curso

Fecha	Sesión de teoría	Sesión de prácticas
23/09	Introducción a la asignatura (teo y pr.)	-- (festivo, apertura curso)
30/09 y 01/10	Introducción al modelado de datos, SQL (T1)	Prácticas de SQL (P1)
07 y 08/10	SQL (II) (T2)	Prácticas de SQL (II) (P2*)
Semana 12/10	--	-- (cambio por IN)
21 y 22/10	Introducción a los sistemas NoSQL (T3)	Bases de datos de documentos (T4)
28 y 29/10	Bases de datos de documentos (P3)	Bases de datos de documentos (P4*)
04 y 05/11	Bases de datos columnares (T5)	Bases de datos columnares (P5)
11 y 12/11	Bases de datos columnares (II)	Bases de datos columnares (P6*)
18 y 19/11	Bases de datos de grafos (T6)	Práctica de bases de datos de grafos (P7*)
26/11	--	Repaso/Pruebas parciales
03/12	--	Repaso/Pruebas parciales

`P2*`, `P4*`, `P6*` y `P7*` son los boletines con entrega; el resto son prácticas guiadas

Calendario de las sesiones

```
SEPTIEMBRE 2026                 CONTENIDO DE LA SEMANA
Lu Ma Mi Ju Vi Sá Do
21 22 23 24 25 26 27              23/09  Introducción a la asignatura
28 29 30                        30/09–01/10  T1/P1 · Modelado de datos y SQL

OCTUBRE 2026
Lu Ma Mi Ju Vi Sá Do
          1  2  3  4
 5  6  7  8  9 10 11              07–08/10  T2/P2 · SQL (II): DDL
12 13 14 15 16 17 18              12/10  (sin clase; cambio por IN)
19 20 21 22 23 24 25              21–22/10  T3/T4 · NoSQL y documentos
26 27 28 29 30 31                 28–29/10  P3/P4 · MongoDB

NOVIEMBRE 2026
Lu Ma Mi Ju Vi Sá Do
                   1
 2  3  4  5  6  7  8              04–05/11  T5/P5 · Cassandra
 9 10 11 12 13 14 15              11–12/11  T5 (II)/P6 · Cassandra
16 17 18 19 20 21 22              18–19/11  T6/P7 · Grafos y Neo4j
23 24 25 26 27 28 29              26/11  Repaso y pruebas parciales
30

DICIEMBRE 2026
Lu Ma Mi Ju Vi Sá Do
    1  2  3  4  5  6              03/12  Repaso y pruebas parciales
```

Estructura de todos los boletines de prácticas

- **Ejercicios numerados** con una celda vacía a continuación para escribir la solución y una comprobación automática (`assert`) justo después de cada uno, para saber al momento si vas bien
- **Guía de estudio para el examen**: cada boletín termina con una lista de cuestiones importantes que debes saber hacer sin la IA delante
- Sirven como **guía de práctica** (aprendes haciendo), **guía de estudio** (repasas antes del examen) e **instrumento de autoevaluación** (los `assert` te dicen si lo has entendido)
- Los boletines marcados con `*` en el cronograma son **evaluables**: se califican y cuentan hacia la nota final

Sistema de evaluación de los boletines evaluables

- **Identificador personal**: al principio de cada boletín evaluable, declares tu DNI
- **Parámetros personalizados**: los umbrales, años y actividad mínima de cada ejercicio salen de tu identificador; cada alumno resuelve una variante distinta
- **Entrega única**: una celda final con una única consulta pequeña y determinista que, al ejecutarse, envía un «indicio» de ejecución a un servidor de evidencias
- **Acuse de recibo**: el servidor devuelve un ID que identifica de forma única tu entrega; puedes comprobarlo en cualquier momento

Evaluación

- Trabajos: **20 %** (opcional)
  - Propuestos por el profesor o el alumnado
  - Estudio de alguna publicación relevante y entrega de trabajo
- Prácticas de la asignatura: **30 %**
- Pruebas periódicas, **examen final** o trabajo final: **50 %**

Dentro de ese 30 % de prácticas

- **15 % la entrega de los boletines evaluables**, con el envío automático que acabamos de ver
- **15 % la parte práctica de la prueba final**: modelar, escribir una consulta, interpretar un plan o reparar una solución
- La prueba final es **teórico-práctica**, y el reparto global de la guía no cambia
- **No hay nota mínima por parte**: se aprueba con **5 sobre 10** en la suma ponderada
- No presentar las prácticas o la prueba final supone **«No presentado»**

> El boletín no es la prueba de que has aprendido: es la preparación para demostrarlo

Prácticas interactivas en el navegador

En el sitio web de la asignatura, sección **Prácticas interactivas**, hay páginas de prueba con consultas para cada sistema, **sin instalar nada**:

Sistema	Sesiones	Motor en el navegador	Qué se practica
SQL	1 y 2	DuckDB-Wasm	Consultas, CTE, funciones ventana, JSON y `EXPLAIN`
MongoDB	3 y 4	mingo (sintaxis PyMongo)	Consultas, actualización y agregación
Cassandra	5 y 6	Simulador de CQL	Particionado, clustering y optimización de consultas
Neo4j	7	Ladybug (Cypher)	Patrones, recorridos y modelado, con el grafo dibujado

Prácticas interactivas: cómo usarlas

- Los datos son los de Stack Overflow en español; en Cassandra, un conjunto sintético pequeño
- Cada ejercicio permite **comprobar** tu resultado contra el de referencia
- El motor del navegador **no es exactamente el de los boletines** (MySQL 8, MongoDB, Cassandra, Neo4j): en Cassandra es un simulador de un subconjunto de CQL, y lo que depende del producto, como `EXPLAIN ANALYZE` o APOC, sigue necesitando el boletín en Colab/Jupyter
- Sirven para practicar en cada base de datos

Bibliografía

- Nathan Marz y James Warren. **Big Data: Principles and Best Practices of Scalable Realtime Data Systems**, Manning, 2015
- Eric Redmond y Jim R. Wilson. **Seven Databases in Seven Weeks: A Guide to Modern Databases and the NoSQL Movement**, Pragmatic Bookshelf, 2012
- Pramod J. Sadalage y Martin Fowler. **NoSQL Distilled: A Brief Guide to the Emerging World of Polyglot Persistence**, Addison-Wesley, 2013

Repositorio de la asignatura

- Guiones de prácticas e información adicional
- Repositorio público: https://github.com/dsevilla/bdge
- Sitio web de la asignatura: dsevilla.github.io/bdge
- Rama del curso: `26-27`

```
$ git clone --depth 1 -b 26-27 https://github.com/dsevilla/bdge.git
$ cd bdge
```

La copia contiene todos los archivos actuales de `26-27`, sin descargar el historial anterior

No hace falta clonarlo para las prácticas: usaremos **Google Colab**; para ejecutarlas en local con Docker, ver las últimas diapositivas

Google Colab

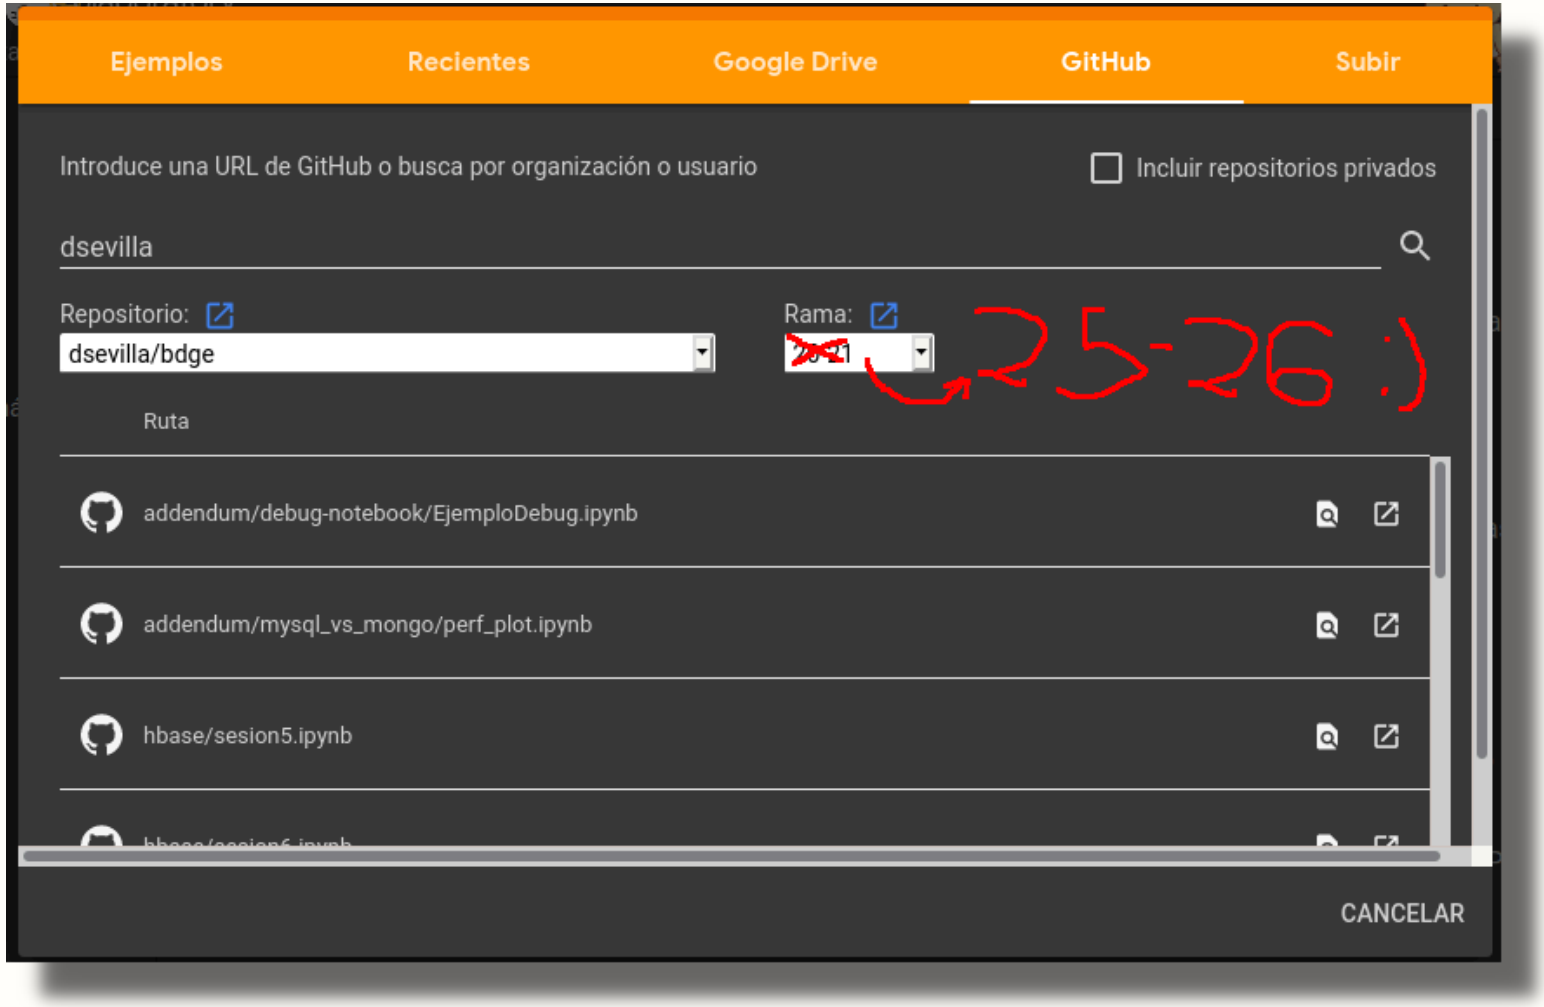
https://colab.research.google.com/



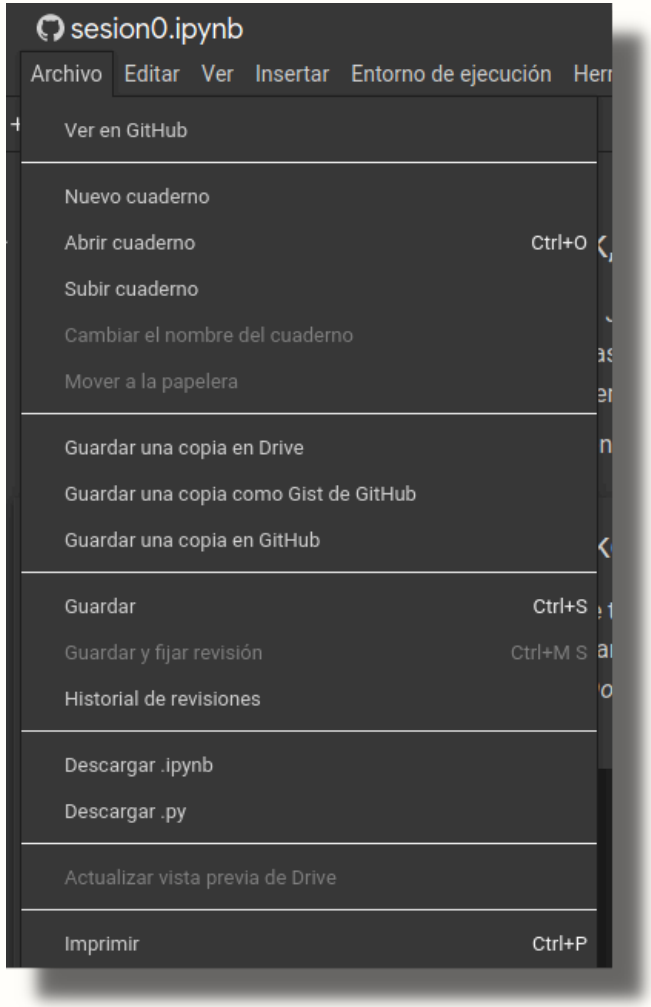
Google Colab

- En **Archivo** → **Abrir cuaderno**, seleccionar **GitHub**
  - Habrá que dar permiso de acceso; pueden limitarse a repositorios públicos
- En el primer cuadro de texto: **dsevilla**
- Repositorio: **dsevilla/bdge**; rama: **26-27**
- Las sesiones están en subdirectorios; por ejemplo, `intro/sesion0.ipynb`
- Al terminar, usar **Archivo** → **Guardar cuaderno** en:
  - **Drive**, o
  - **GitHub** (en un repositorio propio, que puede ser privado)

Google Colab



Google Colab



Ejecutar los notebooks en local: Docker

Cada directorio de sesiones (`intro`, `sql`, `mongo`, `cassandra`, `neo4j`) trae un `docker-compose.yml` que levanta **Jupyter** y, salvo en `intro`, la **base de datos** del tema

```
$ git clone --depth 1 -b 26-27 https://github.com/dsevilla/bdge.git
$ cd bdge/sql              # igual para intro, mongo, cassandra, neo4j...
$ docker compose up
```

- Jupyter en http://localhost:8888 (token `bdge`); lo que se guarda queda en el repositorio local
- `Ctrl+C` para parar; `docker compose down` elimina los contenedores
- En `cassandra`, añadir `-f docker-compose-cassandra.yml`

Cassandra: uno o dos nodos

- `docker-compose-cassandra.yml`: **un nodo**, la más ligera y la habitual
- `docker-compose-cassandra-2.yml`: **dos nodos** (`cassandra1`, `cassandra2`) en la misma red: un clúster pequeño con replicación; más memoria (4 GB de *heap* por nodo) y arranque más lento (hasta un par de minutos)
- Con dos nodos, el notebook corre en el contenedor `notebook` de esa red; desde el equipo sólo va `cqlsh` (puertos 9042 y 9043): cada nodo publica su dirección **dentro** de la red de Docker

```
$ cd cassandra
$ docker compose -f docker-compose-cassandra-2.yml up
```