

Bases de Datos a Gran Escala

Sesión 0 · Introducción


Curso 2026/2027

Diego Sevilla Ruiz

Departamento de Ingeniería y Tecnología de Computadores

Facultad de Informática · Universidad de Murcia

dsevilla@um.es



BODGE

BASES DE DATOS A GRAN ESCALA


III

LA PIEDRA DE LOS DATOS

VALLE DE LOS DATOS. TRAS AÑOS DE BÚSQUEDA, NUESTRO EXPLORADOR DA POR FIN CON LA ENTRADA...



...Y DESCENDE POR PASILLOS CUBIERTOS DE SIGNOS QUE NADIE HA SABIDO LEER EN SIGLOS.



¡¡POR TODOS LOS BYTES!!

Y ALLÍ, EN LA ÚLTIMA SALA...



¡EL MISMO DATO... ESCRITO DE CUATRO MANERAS!



```
<?xml version="1.0">
<ALUMNO>
  <ID>1</ID>
  <NOMBRE>ANA</NOMBRE>
  <NOTA>9.5</NOTA>
</ALUMNO>
<ALUMNO>
  <ID>2</ID>
  <NOMBRE>LUIS</NOMBRE>
  <NOTA>7.0</NOTA>
</ALUMNO>
</ALUMNOS>
```

ID	NOMBRE	NOTA
1	ANA	9.5
2	LUIS	7.0

ESQUEMA + ESTADÍSTICAS PARQUET

XML... CSV... JSON... ¿Y ESO DE ABAJO?

PERO ¿CUÁNDO CONVIENE CADA ESCRITURA? ¿Y DÓNDE SE GUARDAN MILLONES DE PIEDRAS COMO ESTA?



¿LE CUESTA DESCIFRAR SUS DATOS?

¡BDGE! ¡NUEVO!

BASES DE DATOS A GRAN ESCALA

- ☒ LEE XML, CSV, JSON Y PARQUET
- ☒ SQL, DOCUMENTOS, COLUMNAS Y GRAFOS
- ☒ ¡ESCALA A MILLONES DE PIEDRAS!

¡DESCIFRE LA PIEDRA A LA PRIMERA!

9 DE CADA 10 EXPLORADORES LO RECOMENDAN. EL DÉCIMO SIGUE EN EL PASILLO

Bases de Datos a Gran Escala

Curso académico	2026/2027
Titulación	Máster en Big Data
Cuatrimestre	Primero
Curso	Primero
Carácter	Obligatoria
Créditos ECTS	4,5
Departamento	Ingeniería y Tecnología de Computadores

Profesor y horario

Actividad	Profesor	Horario	Aula
Teoría	Diego Sevilla	Miércoles, 16:00–18:00	Lab. 2.4
Prácticas	Diego Sevilla	Jueves, 16:00–17:30	Lab. 2.4

Tutorías y contacto


Tutorías	Contacto
Jueves, 11:00–14:00 y tutorías electrónicas	<code>dsevilla@um.es</code> 868 88 7571 Despacho 3.31

Introducción a la asignatura

Tópicos

- Modelado de datos SQL, NoSQL y NewSQL
- Lenguajes de consulta de datos
- Introducción a los *data lakes*
- Uso de bases de datos clave/valor, documentales, columnares y de grafos
- Formatos de intercambio de datos —CSV, XML, JSON, Parquet y Avro— y particionamiento
- Dimensionamiento correcto de las soluciones de tratamiento de datos

Data Science



La mayor parte del trabajo está en **obtener, limpiar, organizar, transformar y consultar** los datos

Data Access Hitting a Wall



Current practice based on data download (FTP/GREP)

Will not scale to the datasets of tomorrow

- You can GREP 1 MB in a second
- You can GREP 1 GB in a minute
- You can GREP 1 TB in 2 days
- You can GREP 1 PB in 3 years.
- Oh!, and 1PB ~5,000 disks
- At some point you need **indices** to limit search
- **parallel** data search and analysis
- This is where databases can help
- You can FTP 1 MB in 1 sec
- You can FTP 1 GB / min (~1\$)
- ... 2 days and 1K\$
- ... 3 years and 1M\$



[slide src: Jim Gray]

Data Science

- Se pasa un **80-90 %** del tiempo importando datos, organizándolos y optimizando su tratamiento
- Estudiaremos las **abstracciones del modelado de datos** y las herramientas disponibles: las **bases de datos**
 - ¿Cómo se organizan y modelan los datos?
 - ¿Cómo se consultan de forma eficiente?
 - ¿Cómo se tratan los datos heterogéneos?
 - ¿Cómo se gestionan cantidades de datos que no caben en una máquina (*big data*)?
 - Modelado relacional, índices, desnormalización, duplicación y agregación
- Estudiaremos modelado de datos SQL, NoSQL y NewSQL

«...no greater barrier to effective data management will exist than the variety of incompatible data formats, non-aligned data structures, and inconsistent data semantics.»

— Doug Laney, *3-D Data Management: Controlling Data Volume, Velocity and Variety*, Gartner, 2001

eScience, Data Science y el cuarto paradigma


- Tradicionalmente, la ciencia se desarrollaba de forma **empírica**, por observación o reproduciendo condiciones en el laboratorio
- Desde hace unos cientos de años, los **modelos teóricos** se aceptan también como una forma de explicar sucesos y sugerir nuevos experimentos
- En los últimos ~50 años, la **simulación** permite reproducir condiciones especiales o no reproducibles. Para modelos demasiado complejos para resolverlos analíticamente, se parte de un estado inicial y se estudia su evolución

Cuarto paradigma

- Hoy: **exploración basada en datos**
 - Unifica teoría, experimentación y simulación
 - Los datos se capturan por instrumentos o se generan por simulaciones
 - Son procesados por software; la información y el conocimiento extraído se almacenan en ordenadores
 - Los científicos analizan ficheros y bases de datos con nuevas herramientas estadísticas y de datos, capaces de gestionar cada vez más volumen
 - En vez de «**preguntar al mundo**», se combinan conjuntos de datos «**descargados**» de formas antes no previstas
- **Jim Gray**, *The Fourth Paradigm*, Microsoft Research, 2009


Huracán Sandy, 2012

<https://rpubs.com/JoFrhwld/sandy> · Howe, 2013




¿Cuándo introdujo Apple «Swift»?

Una mirada al tag `swift` de todas las preguntas de Stack Overflow




¿Bases de datos hoy?




¿Bases de datos hoy?

- No hay fuentes fiables que muestren el uso real de las bases de datos
- Referencias útiles:
 - DB-Engines Ranking
 - 2024 NoSQL Database Trend Report, basado en el JetBrains 2023 Developer Ecosystem
 - Stack Overflow Developer Survey 2025
 - JetBrains 2024 Developer Ecosystem: Databases
 - Encuesta DeveloperWeek 2019, con más de 8 000 desarrolladores


SQL, NoSQL y persistencia polígloa



Bases de datos más populares




Bases de datos emergentes




Comparación con DB-Engines

<https://db-engines.com/en/ranking>




Bases de datos usadas en el último año

JetBrains, 2024




Reciprocidad entre bases de datos


Alta en combinaciones SQL + NoSQL




Tareas que más consumen tiempo




Métricas más importantes en bases de datos




Uso de bases de datos según el tamaño de la empresa



Stack Overflow: uso de bases de datos



Stack Overflow: bases de datos queridas y admiradas




Resumen

- Las bases de datos relacionales no van a desaparecer, aunque no sean las favoritas de los desarrolladores: casi la mitad combina SGBDR y NoSQL
- NoSQL se adopta para roles especializados: Redis y MongoDB muestran una alta reciprocidad con las bases de datos relacionales
- La IA y el *machine learning* impulsarán la demanda de datos
- Aumentan las nubes especializadas y los datos gestionados
- NoSQL se usará cada vez más con sistemas distribuidos

Fuentes de datos para proceso


What types of data sources do you work with?



Although the majority uses local files, the share of those using SQL databases grew by 10 percentage points over the past year, highlighting the importance of SQL for data science.


Tipos de proceso de datos

What types of data do you analyze?



Show less

In which of the following activities are you involved?



Show less

Planificación del curso

Fecha	Sesión de teoría	Sesión de prácticas
23/09	Introducción a la asignatura (teo y pr.)	-- (festivo, apertura curso)
30/09 y 01/10	Introducción al modelado de datos, SQL (T1)	Prácticas de SQL (P1)
07 y 08/10	SQL (II) (T2)	Prácticas de SQL (II) (P2*)
Semana 12/10	--	-- (cambio por IN)
21 y 22/10	Introducción a los sistemas NoSQL (T3)	Bases de datos de documentos (T4)
28 y 29/10	Bases de datos de documentos (P3)	Bases de datos de documentos (P4*)
04 y 05/11	Bases de datos columnares (T5)	Bases de datos columnares (P5)
11 y 12/11	Bases de datos columnares (II)	Bases de datos columnares (P6*)
18 y 19/11	Bases de datos de grafos (T6)	Práctica de bases de datos de grafos (P7*)
26/11	--	Repaso/Pruebas parciales
03/12	--	Repaso/Pruebas parciales

P2*, P4*, P6* y P7* son los boletines con entrega; el resto son prácticas guiadas

Calendario de las sesiones

SEPTIEMBRE 2026

Lu	Ma	Mi	Ju	Vi	Sá	Do
21	22	23	24	25	26	27
28	29	30				

OCTUBRE 2026

Lu	Ma	Mi	Ju	Vi	Sá	Do
			1	2	3	4
5	6	7	8	9	10	11
12	13	14	15	16	17	18
19	20	21	22	23	24	25
26	27	28	29	30	31	

NOVIEMBRE 2026

Lu	Ma	Mi	Ju	Vi	Sá	Do
						1
2	3	4	5	6	7	8
9	10	11	12	13	14	15
16	17	18	19	20	21	22
23	24	25	26	27	28	29
30						

DICIEMBRE 2026

Lu	Ma	Mi	Ju	Vi	Sá	Do
	1	2	3	4	5	6

CONTENIDO DE LA SEMANA

23/09 Introducción a la asignatura
30/09-01/10 T1/P1 · Modelado de datos y SQL

07-08/10 T2/P2 · SQL (II): DDL
12/10 (sin clase; cambio por IN)
21-22/10 T3/T4 · NoSQL y documentos
28-29/10 P3/P4 · MongoDB

04-05/11 T5/P5 · Cassandra
11-12/11 T5 (II)/P6 · Cassandra
18-19/11 T6/P7 · Grafos y Neo4j
26/11 Repaso y pruebas parciales

03/12 Repaso y pruebas parciales

Estructura de todos los boletines de prácticas

- **Ejercicios numerados** con una celda vacía a continuación para escribir la solución y una comprobación automática (`assert`) justo después de cada uno, para saber al momento si vas bien
- **Guía de estudio para el examen:** cada boletín termina con una lista de cuestiones importantes que debes saber hacer sin la IA delante
- Sirven como **guía de práctica** (aprendes haciendo), **guía de estudio** (repasas antes del examen) e **instrumento de autoevaluación** (los `assert` te dicen si lo has entendido)
- Los boletines marcados con * en el cronograma son **evaluables**: se califican y cuentan hacia la nota final

Sistema de evaluación de los boletines evaluables

- **Identificador personal:** al principio de cada boletín evaluable, declares tu DNI
- **Parámetros personalizados:** los umbrales, años y actividad mínima de cada ejercicio salen de tu identificador; cada alumno resuelve una variante distinta
- **Entrega única:** una celda final con una única consulta pequeña y determinista que, al ejecutarse, envía un «indicio» de ejecución a un servidor de evidencias
- **Acuse de recibo:** el servidor devuelve un ID que identifica de forma única tu entrega; puedes comprobarlo en cualquier momento

Evaluación

- Trabajos: **20 %** (opcional)
 - Propuestos por el profesor o el alumnado
 - Estudio de alguna publicación relevante y entrega de trabajo
- Prácticas de la asignatura: **30 %**
- Pruebas periódicas, **examen final** o trabajo final: **50 %**

Dentro de ese 30 % de prácticas

- **15 % la entrega de los boletines evaluables**, con el envío automático que acabamos de ver
- **15 % la parte práctica de la prueba final**: modelar, escribir una consulta, interpretar un plan o reparar una solución
- La prueba final es **teórico-práctica**, y el reparto global de la guía no cambia
- **No hay nota mínima por parte**: se aprueba con **5 sobre 10** en la suma ponderada
- No presentar las prácticas o la prueba final supone **«No presentado»**

El boletín no es la prueba de que has aprendido: es la preparación para demostrarlo

Prácticas interactivas en el navegador

En el [sitio web de la asignatura](#), sección **Prácticas interactivas**, hay páginas de prueba con consultas para cada sistema, **sin instalar nada**:

Sistema	Sesiones	Motor en el navegador	Qué se practica
SQL	1 y 2	DuckDB-Wasm	Consultas, CTE, funciones ventana, JSON y EXPLAIN
MongoDB	3 y 4	mingo (sintaxis PyMongo)	Consultas, actualización y agregación
Cassandra	5 y 6	Simulador de CQL	Particionado, clustering y optimización de consultas
Neo4j	7	Ladybug (Cypher)	Patrones, recorridos y modelado, con el grafo dibujado

Prácticas interactivas: cómo usarlas

- Los datos son los de Stack Overflow en español; en Cassandra, un conjunto sintético pequeño
- Cada ejercicio permite **comprobar** tu resultado contra el de referencia
- El motor del navegador **no es exactamente el de los boletines** (MySQL 8, MongoDB, Cassandra, Neo4j): en Cassandra es un simulador de un subconjunto de CQL, y lo que depende del producto, como `EXPLAIN ANALYZE` o APOC, sigue necesitando el boletín en Colab/Jupyter
- Sirven para practicar en cada base de datos

Bibliografía

- Nathan Marz y James Warren. **Big Data: Principles and Best Practices of Scalable Realtime Data Systems**, Manning, 2015
- Eric Redmond y Jim R. Wilson. **Seven Databases in Seven Weeks: A Guide to Modern Databases and the NoSQL Movement**, Pragmatic Bookshelf, 2012
- Pramod J. Sadalage y Martin Fowler. **NoSQL Distilled: A Brief Guide to the Emerging World of Polyglot Persistence**, Addison-Wesley, 2013

Repositorio de la asignatura

- Guiones de prácticas e información adicional
- Repositorio público: <https://github.com/dsevilla/bdge>
- Sitio web de la asignatura: dsevilla.github.io/bdge
- Rama del curso: **26-27**


```
$ git clone --depth 1 -b 26-27 https://github.com/dsevilla/bdge.git  
$ cd bdge
```

La copia contiene todos los archivos actuales de **26-27**, sin descargar el historial anterior

No hace falta clonarlo para las prácticas: usaremos **Google Colab**; para ejecutarlas en local con Docker o Podman, ver las últimas diapositivas

Google Colab

<https://colab.research.google.com/>



Google Colab

- En **Archivo** → **Abrir cuaderno**, seleccionar **GitHub**
 - Habrá que dar permiso de acceso; pueden limitarse a repositorios públicos
- En el primer cuadro de texto: **dsevilla**
- Repositorio: **dsevilla/bdge**; rama: **26-27**
- Las sesiones están en subdirectorios; por ejemplo,
`intro/sesion0.ipynb`
- Al terminar, usar **Archivo** → **Guardar cuaderno** en:
 - **Drive**, o
 - **GitHub** (en un repositorio propio, que puede ser privado)

Google Colab

EjemplosRecientesGoogle DriveGitHubSubir

Introduce una URL de GitHub o busca por organización o usuario

☐ Incluir repositorios privados

dsevilla

Repositorio: Rama:

dsevilla/bdge

~~2021~~

Ruta

addendum/debug-notebook/EjemploDebug.ipynb

addendum/mysql_vs_mongo/perf_plot.ipynb

hbase/sesion5.ipynb

hbase/sesion6.ipynb


CANCELAR

Handwritten red text: 25-26 :) with an arrow pointing to the branch dropdown.

BDGE · Curso 2026/2027

43

Google Colab



Ejecutar los notebooks en local: Docker

Cada directorio de sesiones (`intro` , `sql` , `mongo` , `cassandra` , `neo4j`) trae un `docker-compose.yml` que levanta **Jupyter** y, salvo en `intro` , la **base de datos** del tema

```
$ git clone --depth 1 -b 26-27 https://github.com/dsevilla/bdge.git
$ cd bdge/sql # igual para intro, mongo, cassandra, neo4j...
$ docker compose up
```

- Jupyter en <http://localhost:8888> (token `bdge`); lo que se guarda queda en el repositorio local
- `Ctrl+C` para parar; `docker compose down` elimina los contenedores
- En `cassandra` , añadir `-f docker-compose-cassandra.yml`

Ejecutar los notebooks en local: Podman

Podman ejecuta los mismos ficheros sin privilegios (*rootless*), con un segundo fichero, `docker-compose.podman.yml`, que hace que tu usuario aparezca en el contenedor como el de Jupyter (`keep-id`); sin él, Jupyter no puede guardar en el repositorio

```
$ cd sql # igual para intro, mongo, neo4j...
$ podman compose -f docker-compose.yml -f docker-compose.podman.yml up
```

- Jupyter, el token y `podman compose down`, como con Docker
- En `cassandra`: `docker-compose-cassandra.yml` y `docker-compose-cassandra.podman.yml`
- `podman compose` necesita `docker-compose` o `podman-compose` instalado

Podman: preparación, una sola vez

Activar el socket de Podman para tu usuario, y decirle dónde buscar las imágenes con nombre corto (`mysql:8` , `mongo:8.3` ...):

```
$ systemctl --user enable --now podman.socket  
$ mkdir -p ~/.config/containers/registries.conf.d  
$ nano ~/.config/containers/registries.conf.d/10-docker-hub.conf
```

Contenido del fichero:

```
unqualified-search-registries = ["docker.io"]
```

Cassandra: uno o dos nodos

- `docker-compose-cassandra.yml` : **un nodo**, la más ligera y la habitual
- `docker-compose-cassandra-2.yml` : **dos nodos** (`cassandra1` , `cassandra2`) en la misma red: un clúster pequeño con replicación; más memoria (4 GB de *heap* por nodo) y arranque más lento (hasta un par de minutos)
- Con dos nodos, el notebook corre en el contenedor `notebook` de esa red; desde el equipo sólo va `cqlsh` (puertos 9042 y 9043): cada nodo publica su dirección **dentro** de la red de Docker

```
$ cd cassandra
$ docker compose -f docker-compose-cassandra-2.yml up
$ podman compose \
  -f docker-compose-cassandra-2.yml \
  -f docker-compose-cassandra.podman.yml up
```