

# Bases de Datos a Gran Escala

## Sesión 0 · Introducción

**Curso 2026/2027**

Diego Sevilla Ruiz

Departamento de Ingeniería y Tecnología de Computadores

Facultad de Informática · Universidad de Murcia

[dsevilla@um.es](mailto:dsevilla@um.es)



**BODGE**

BASES DE DATOS A GRAN ESCALA

III

# Bases de Datos a Gran Escala

---

|                        |                                         |
|------------------------|-----------------------------------------|
| <b>Curso académico</b> | 2026/2027                               |
| <b>Titulación</b>      | Máster en Big Data                      |
| <b>Cuatrimestre</b>    | Primero                                 |
| <b>Curso</b>           | Primero                                 |
| <b>Carácter</b>        | Obligatoria                             |
| <b>Créditos ECTS</b>   | 4,5                                     |
| <b>Departamento</b>    | Ingeniería y Tecnología de Computadores |

# Profesor y horario

---

| Actividad | Profesor      | Horario                | Aula     |
|-----------|---------------|------------------------|----------|
| Teoría    | Diego Sevilla | Miércoles, 16:00–18:00 | Lab. 2.4 |
| Prácticas | Diego Sevilla | Jueves, 16:00–17:30    | Lab. 2.4 |

## Tutorías y contacto

| Tutorías                                       | Contacto                                                    |
|------------------------------------------------|-------------------------------------------------------------|
| Jueves, 11:00–14:00<br>y tutorías electrónicas | <code>dsevilla@um.es</code><br>868 88 7571<br>Despacho 3.31 |

# Introducción a la asignatura


---

## Tópicos

- Modelado de datos SQL, NoSQL y NewSQL
- Lenguajes de consulta de datos
- Introducción a los *data lakes*
- Uso de bases de datos clave/valor, documentales, columnares y de grafos
- Formatos de intercambio de datos —CSV, XML, JSON, Parquet y Avro— y particionamiento
- Dimensionamiento correcto de las soluciones de tratamiento de datos

# Data Science

---



La mayor parte del trabajo está en **obtener, limpiar, organizar, transformar y consultar** los datos.

# Data Access Hitting a Wall



## Current practice based on data download (FTP/GREP)

### Will not scale to the datasets of tomorrow

- You can GREP 1 MB in a second
- You can GREP 1 GB in a minute
- You can GREP 1 TB in 2 days
- You can GREP 1 PB in 3 years.
- Oh!, and 1PB ~5,000 disks
- At some point you need **indices** to limit search
- **parallel** data search and analysis
- This is where databases can help
- You can FTP 1 MB in 1 sec
- You can FTP 1 GB / min (~1\$)
- ... 2 days and 1K\$
- ... 3 years and 1M\$



[slide src: Jim Gray]

# Data Science

---

- Se pasa un **80-90 %** del tiempo importando datos, organizándolos y optimizando su tratamiento
- Estudiaremos las **abstracciones del modelado de datos** y las herramientas disponibles: las **bases de datos**
  - ¿Cómo se organizan y modelan los datos?
  - ¿Cómo se consultan de forma eficiente?
  - ¿Cómo se tratan los datos heterogéneos?
  - ¿Cómo se gestionan cantidades de datos que no caben en una máquina (*big data*)?
  - Modelado relacional, índices, desnormalización, duplicación y agregación
- Estudiaremos modelado de datos SQL, NoSQL y NewSQL

«...no greater barrier to effective data management will exist than the variety of incompatible data formats, non-aligned data structures, and inconsistent data semantics.»

— Doug Laney, *3-D Data Management: Controlling Data Volume, Velocity and Variety*, Gartner, 2001

# eScience, Data Science y el cuarto paradigma

---

- Tradicionalmente, la ciencia se desarrollaba de forma **empírica**, por observación o reproduciendo condiciones en el laboratorio
- Desde hace unos cientos de años, los **modelos teóricos** se aceptan también como una forma de explicar sucesos y sugerir nuevos experimentos
- En los últimos ~50 años, la **simulación** permite reproducir condiciones especiales o no reproducibles. Para modelos demasiado complejos para resolverlos analíticamente, se parte de un estado inicial y se estudia su evolución


# Cuarto paradigma

---

- Hoy: **exploración basada en datos**
  - Unifica teoría, experimentación y simulación
  - Los datos se capturan por instrumentos o se generan por simulaciones
  - Son procesados por software; la información y el conocimiento extraído se almacenan en ordenadores
  - Los científicos analizan ficheros y bases de datos con nuevas herramientas estadísticas y de datos, capaces de gestionar cada vez más volumen
  - En vez de «**preguntar al mundo**», se combinan conjuntos de datos «**descargados**» de formas antes no previstas
- **Jim Gray**, *The Fourth Paradigm*, Microsoft Research, 2009

# Huracán Sandy, 2012

<https://rpubs.com/JoFrhwld/sandy> · Howe, 2013



# ¿Cuándo introdujo Apple «Swift»?

Una mirada al tag `swift` de todas las preguntas de Stack Overflow.



# ¿Bases de datos hoy?



# ¿Bases de datos hoy?

---

- No hay fuentes fiables que muestren el uso real de las bases de datos
- Referencias útiles:
  - DB-Engines Ranking
  - 2024 NoSQL Database Trend Report, basado en el JetBrains 2023 Developer Ecosystem
  - Stack Overflow Developer Survey 2025
  - JetBrains 2024 Developer Ecosystem: Databases
  - Encuesta DeveloperWeek 2019, con más de 8 000 desarrolladores

# SQL, NoSQL y persistencia polígloa

---



# Bases de datos más populares



# Bases de datos emergentes



# Comparación con DB-Engines

<https://db-engines.com/en/ranking>




# Bases de datos usadas en el último año

JetBrains, 2024.



# Reciprocidad entre bases de datos

## Alta en combinaciones SQL + NoSQL.




# Tareas que más consumen tiempo



# Métricas más importantes en bases de datos

---



# Uso de bases de datos según el tamaño de la empresa



# Stack Overflow: uso de bases de datos



# Stack Overflow: bases de datos queridas y admiradas




# Resumen

---

- Las bases de datos relacionales no van a desaparecer, aunque no sean las favoritas de los desarrolladores: casi la mitad combina SGBDR y NoSQL
- NoSQL se adopta para roles especializados: Redis y MongoDB muestran una alta reciprocidad con las bases de datos relacionales
- La IA y el *machine learning* impulsarán la demanda de datos
- Aumentan las nubes especializadas y los datos gestionados
- NoSQL se usará cada vez más con sistemas distribuidos

# Fuentes de datos para proceso


## What types of data sources do you work with?



Although the majority uses local files, the share of those using SQL databases grew by 10 percentage points over the past year, highlighting the importance of SQL for data science.


# Tipos de proceso de datos

## What types of data do you analyze?



Show less

## In which of the following activities are you involved?



Show less

# Planificación del curso

| Fecha         | Sesión de teoría                            | Sesión de prácticas                        |
|---------------|---------------------------------------------|--------------------------------------------|
| 23/09         | Introducción a la asignatura (teo y pr.)    | -- (festivo, apertura curso)               |
| 30/09 y 01/10 | Introducción al modelado de datos, SQL (T1) | Prácticas de SQL (P1)                      |
| 07 y 08/10    | SQL (II) (T2)                               | Prácticas de SQL (II) (P2*)                |
| Semana 12/10  | --                                          | -- (cambio por IN)                         |
| 21 y 22/10    | Introducción a los sistemas NoSQL (T3)      | Bases de datos de documentos (T4)          |
| 28 y 29/10    | Bases de datos de documentos (P3)           | Bases de datos de documentos (P4*)         |
| 04 y 05/11    | Bases de datos columnares (T5)              | Bases de datos columnares (P5)             |
| 11 y 12/11    | Bases de datos columnares (II)              | Bases de datos columnares (P6*)            |
| 18 y 19/11    | Bases de datos de grafos (T6)               | Práctica de bases de datos de grafos (P7*) |
| 26/11         | --                                          | Repaso/Pruebas parciales                   |
| 03/12         | --                                          | Repaso/Pruebas parciales                   |

# Calendario de las sesiones

## SEPTIEMBRE 2026

| Lu | Ma | Mi | Ju | Vi | Sá | Do |
|----|----|----|----|----|----|----|
| 21 | 22 | 23 | 24 | 25 | 26 | 27 |
| 28 | 29 | 30 |    |    |    |    |

## OCTUBRE 2026

| Lu | Ma | Mi | Ju | Vi | Sá | Do |
|----|----|----|----|----|----|----|
|    |    |    | 1  | 2  | 3  | 4  |
| 5  | 6  | 7  | 8  | 9  | 10 | 11 |
| 12 | 13 | 14 | 15 | 16 | 17 | 18 |
| 19 | 20 | 21 | 22 | 23 | 24 | 25 |
| 26 | 27 | 28 | 29 | 30 | 31 |    |

## NOVIEMBRE 2026

| Lu | Ma | Mi | Ju | Vi | Sá | Do |
|----|----|----|----|----|----|----|
|    |    |    |    |    |    | 1  |
| 2  | 3  | 4  | 5  | 6  | 7  | 8  |
| 9  | 10 | 11 | 12 | 13 | 14 | 15 |
| 16 | 17 | 18 | 19 | 20 | 21 | 22 |
| 23 | 24 | 25 | 26 | 27 | 28 | 29 |
| 30 |    |    |    |    |    |    |

## DICIEMBRE 2026

| Lu | Ma | Mi | Ju | Vi | Sá | Do |
|----|----|----|----|----|----|----|
|    | 1  | 2  | 3  | 4  | 5  | 6  |

## CONTENIDO DE LA SEMANA

23/09 Introducción a la asignatura  
30/09-01/10 T1/P1 · Modelado de datos y SQL

07-08/10 T2/P2 · SQL (II): DDL  
12/10 (sin clase; cambio por IN)  
21-22/10 T3/T4 · NoSQL y documentos  
28-29/10 P3/P4 · MongoDB

04-05/11 T5/P5 · Cassandra  
11-12/11 T5 (II)/P6 · Cassandra  
18-19/11 T6/P7 · Grafos y Neo4j  
26/11 Repaso y pruebas parciales

03/12 Repaso y pruebas parciales

# Evaluación

---

- Trabajos: **20 %** (opcional)
  - Propuestos por el profesor o el alumnado
  - Estudio de alguna publicación relevante y entrega de trabajo
- Prácticas de la asignatura: **30 %**
- Pruebas periódicas, **examen final** o trabajo final: **50 %**

# Bibliografía

---

- Nathan Marz y James Warren. **Big Data: Principles and Best Practices of Scalable Realtime Data Systems**, Manning, 2015
- Eric Redmond y Jim R. Wilson. **Seven Databases in Seven Weeks: A Guide to Modern Databases and the NoSQL Movement**, Pragmatic Bookshelf, 2012
- Pramod J. Sadalage y Martin Fowler. **NoSQL Distilled: A Brief Guide to the Emerging World of Polyglot Persistence**, Addison-Wesley, 2013

# Repositorio de la asignatura

---


- Guiones de prácticas e información adicional
- Repositorio público: <https://github.com/dsevilla/bdge>
- Rama del curso: 26-27

```
$ git clone https://github.com/dsevilla/bdge.git  
$ cd bdge  
$ git switch 26-27
```

No hace falta clonarlo para las prácticas: usaremos **Google Colab**.

# Google Colab

<https://colab.research.google.com/>



# Google Colab

---

- En **Archivo** → **Abrir cuaderno**, seleccionar **GitHub**
  - Habrá que dar permiso de acceso; pueden limitarse a repositorios públicos
- En el primer cuadro de texto: **dsevilla**
- Repositorio: **dsevilla/bdge**; rama: **26-27**
- Las sesiones están en subdirectorios; por ejemplo, `intro/sesion0.ipynb`
- Al terminar, usar **Archivo** → **Guardar cuaderno** en:
  - **Drive**, o
  - **GitHub** (en un repositorio propio, que puede ser privado)

# Google Colab

EjemplosRecientesGoogle DriveGitHubSubir

Introduce una URL de GitHub o busca por organización o usuario

☐ Incluir repositorios privados

dsevilla

Repositorio: Rama:

dsevilla/bdge

~~25-26~~

Ruta

addendum/debug-notebook/EjemploDebug.ipynb

addendum/mysql\_vs\_mongo/perf\_plot.ipynb

hbase/sesion5.ipynb

hbase/sesion6.ipynb

CANCELAR

25-26 :)

BDGE · Curso 2026/2027

37

# Google Colab

---

