Bases de Datos a Gran Escala

Sesión 0 · Introducción

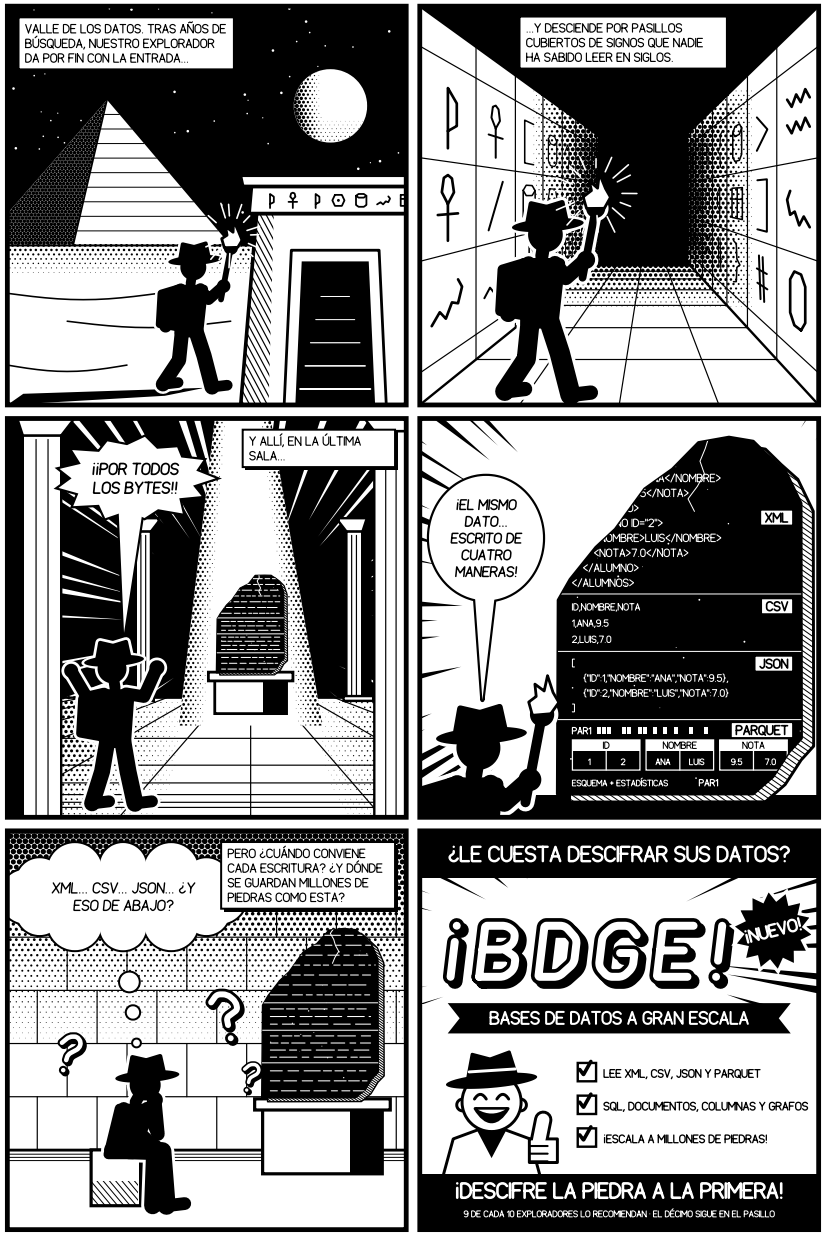
Curso 2026/2027

Diego Sevilla Ruiz
Departamento de Ingeniería y Tecnología de Computadores
Facultad de Informática · Universidad de Murcia

dsevilla@um.es


BDGE
BASES DE DATOS A GRAN ESCALA
III

LA PIEDRA DE LOS DATOS



Bases de Datos a Gran Escala

Curso académico	2026/2027
Titulación	Máster en Big Data
Cuatrimestre	Primero
Curso	Primero
Carácter	Obligatoria
Créditos ECTS	4,5
Departamento	Ingeniería y Tecnología de Computadores

Profesor y horario

Actividad	Profesor	Horario	Aula
Teoría	Diego Sevilla	Miércoles, 16:00–18:00	Lab. 2.4
Prácticas	Diego Sevilla	Jueves, 16:00–17:30	Lab. 2.4

Tutorías y contacto

Tutorías	Contacto
Jueves, 11:00–14:00 y tutorías electrónicas	`dsevilla@um.es` 868 88 7571 Despacho 3.31

Introducción a la asignatura

Tópicos

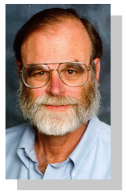
- Modelado de datos SQL, NoSQL y NewSQL
- Lenguajes de consulta de datos
- Introducción a los *data lakes*
- Uso de bases de datos clave/valor, documentales, columnares y de grafos
- Formatos de intercambio de datos —CSV, XML, JSON, Parquet y Avro — y particionamiento
- Dimensionamiento correcto de las soluciones de tratamiento de datos

Data Science



La mayor parte del trabajo está en **obtener, limpiar, organizar, transformar y consultar** los datos

Data Access Hitting a Wall



Current practice based on data download (FTP/GREP)
Will not scale to the datasets of tomorrow

- You can GREP 1 MB in a second
- You can GREP 1 GB in a minute
- You can GREP 1 TB in 2 days
- You can GREP 1 PB in 3 years.

- Oh!, and 1PB ~5,000 disks

- At some point you need
  indices to limit search
  parallel data search and analysis
- This is where databases can help

- You can FTP 1 MB in 1 sec
- You can FTP 1 GB / min (~1$)
- … 2 days and 1K$
- … 3 years and 1M$



[slide src: Jim Gray]

Data Science

- Se pasa un **80–90 %** del tiempo importando datos, organizándolos y optimizando su tratamiento
- Estudiaremos las **abstracciones del modelado de datos** y las herramientas disponibles: las **bases de datos**
  - ¿Cómo se organizan y modelan los datos?
  - ¿Cómo se consultan de forma eficiente?
  - ¿Cómo se tratan los datos heterogéneos?
  - ¿Cómo se gestionan cantidades de datos que no caben en una máquina (*big data*)?
  - Modelado relacional, índices, desnormalización, duplicación y agregación
- Estudiaremos modelado de datos SQL, NoSQL y NewSQL

> «...no greater barrier to effective data management will exist than the variety of incompatible data formats, non-aligned data structures, and inconsistent data semantics.»
> — Doug Laney, *3-D Data Management: Controlling Data Volume, Velocity and Variety*, Gartner, 2001

eScience, Data Science y el cuarto paradigma

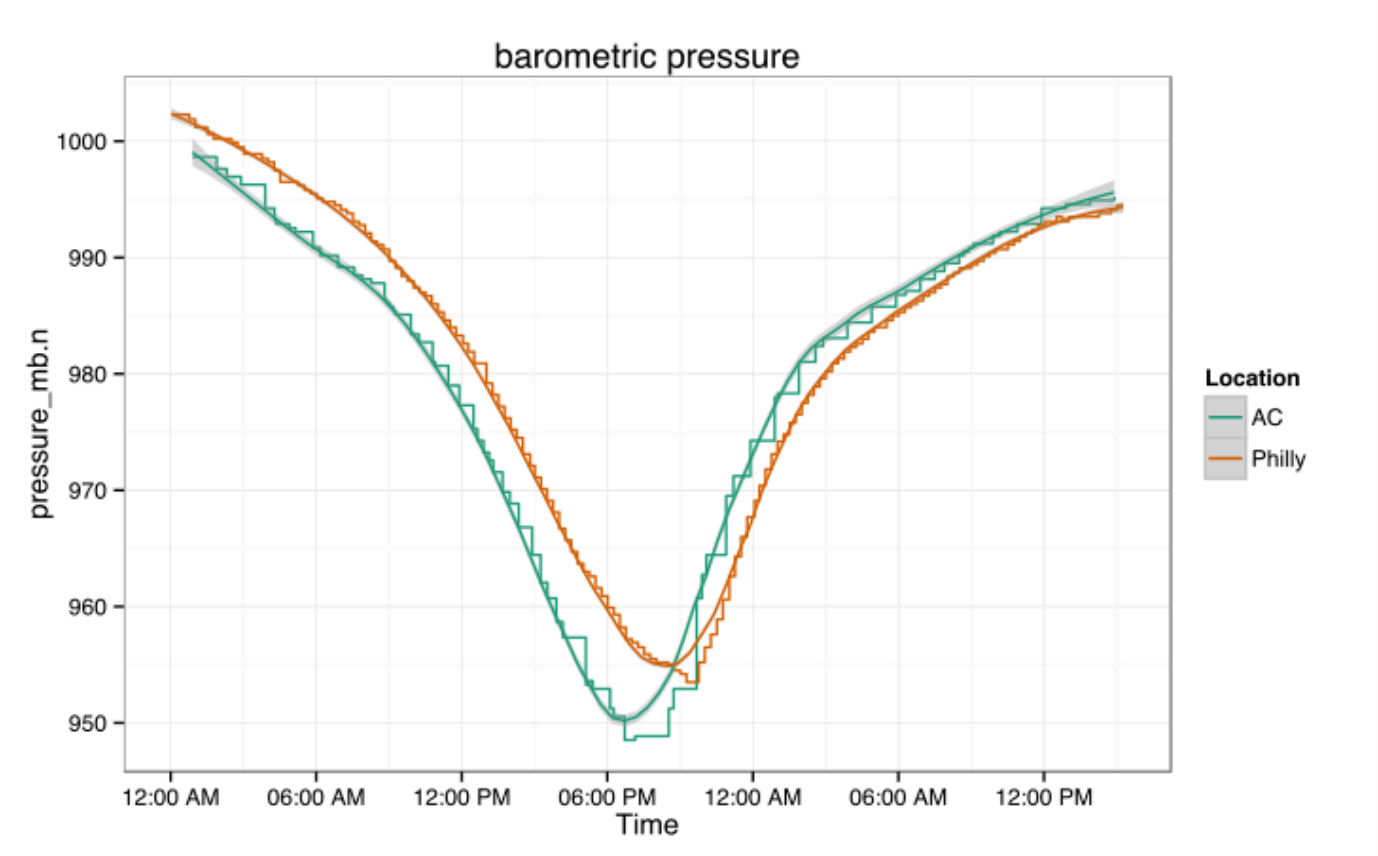
- Tradicionalmente, la ciencia se desarrollaba de forma **empírica**, por observación o reproduciendo condiciones en el laboratorio
- Desde hace unos cientos de años, los **modelos teóricos** se aceptan también como una forma de explicar sucesos y sugerir nuevos experimentos
- En los últimos ~50 años, la **simulación** permite reproducir condiciones especiales o no reproducibles. Para modelos demasiado complejos para resolverlos analíticamente, se parte de un estado inicial y se estudia su evolución

Cuarto paradigma

- Hoy: **exploración basada en datos**
  - Unifica teoría, experimentación y simulación
  - Los datos se capturan por instrumentos o se generan por simulaciones
  - Son procesados por software; la información y el conocimiento extraído se almacenan en ordenadores
  - Los científicos analizan ficheros y bases de datos con nuevas herramientas estadísticas y de datos, capaces de gestionar cada vez más volumen
  - En vez de «**preguntar al mundo**», se combinan conjuntos de datos «**descargados**» de formas antes no previstas
- **Jim Gray**, *The Fourth Paradigm*, Microsoft Research, 2009

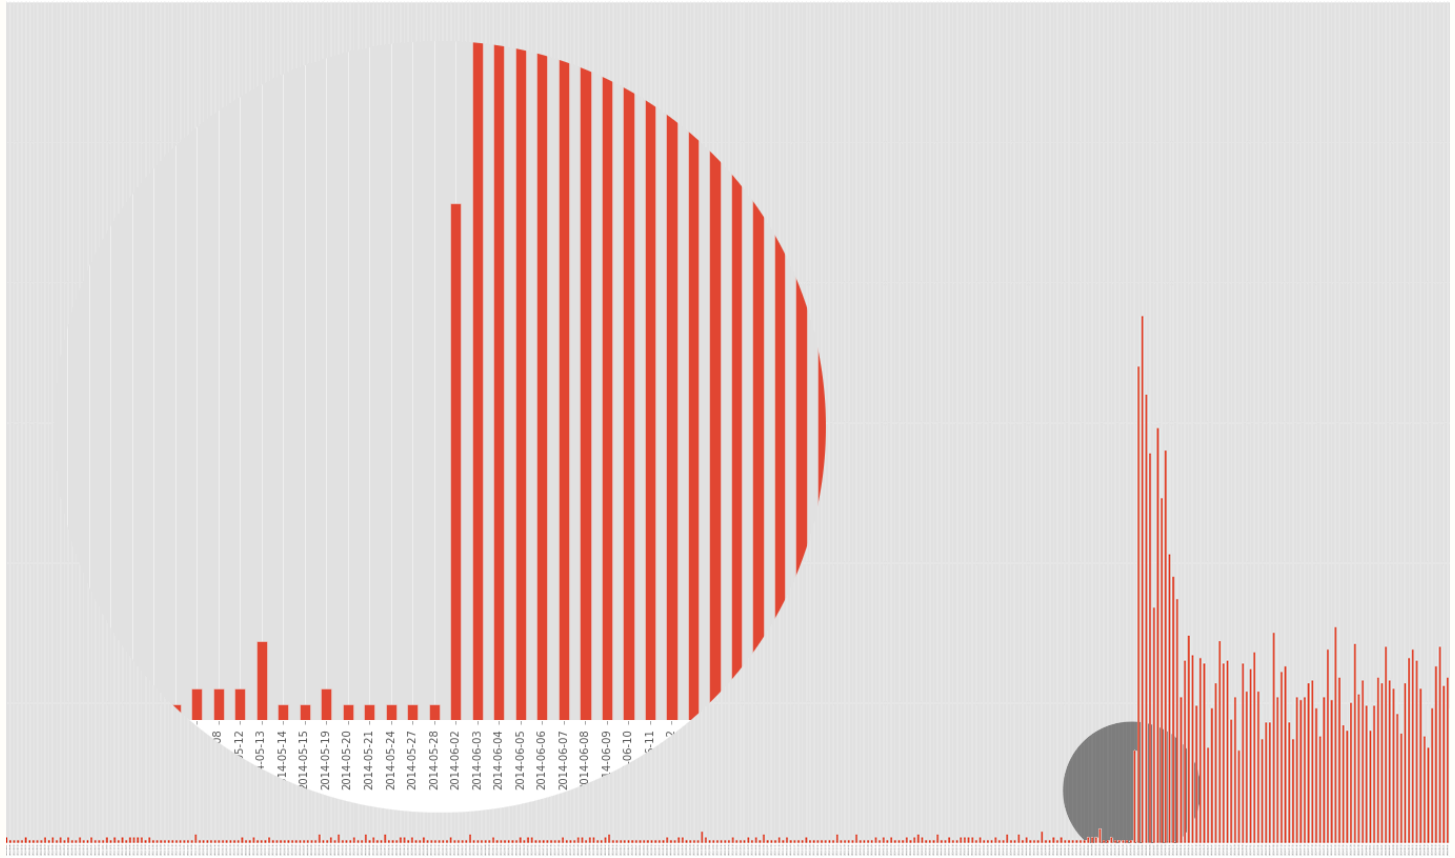
Huracán Sandy, 2012

https://rpubs.com/JoFrhwld/sandy · Howe, 2013

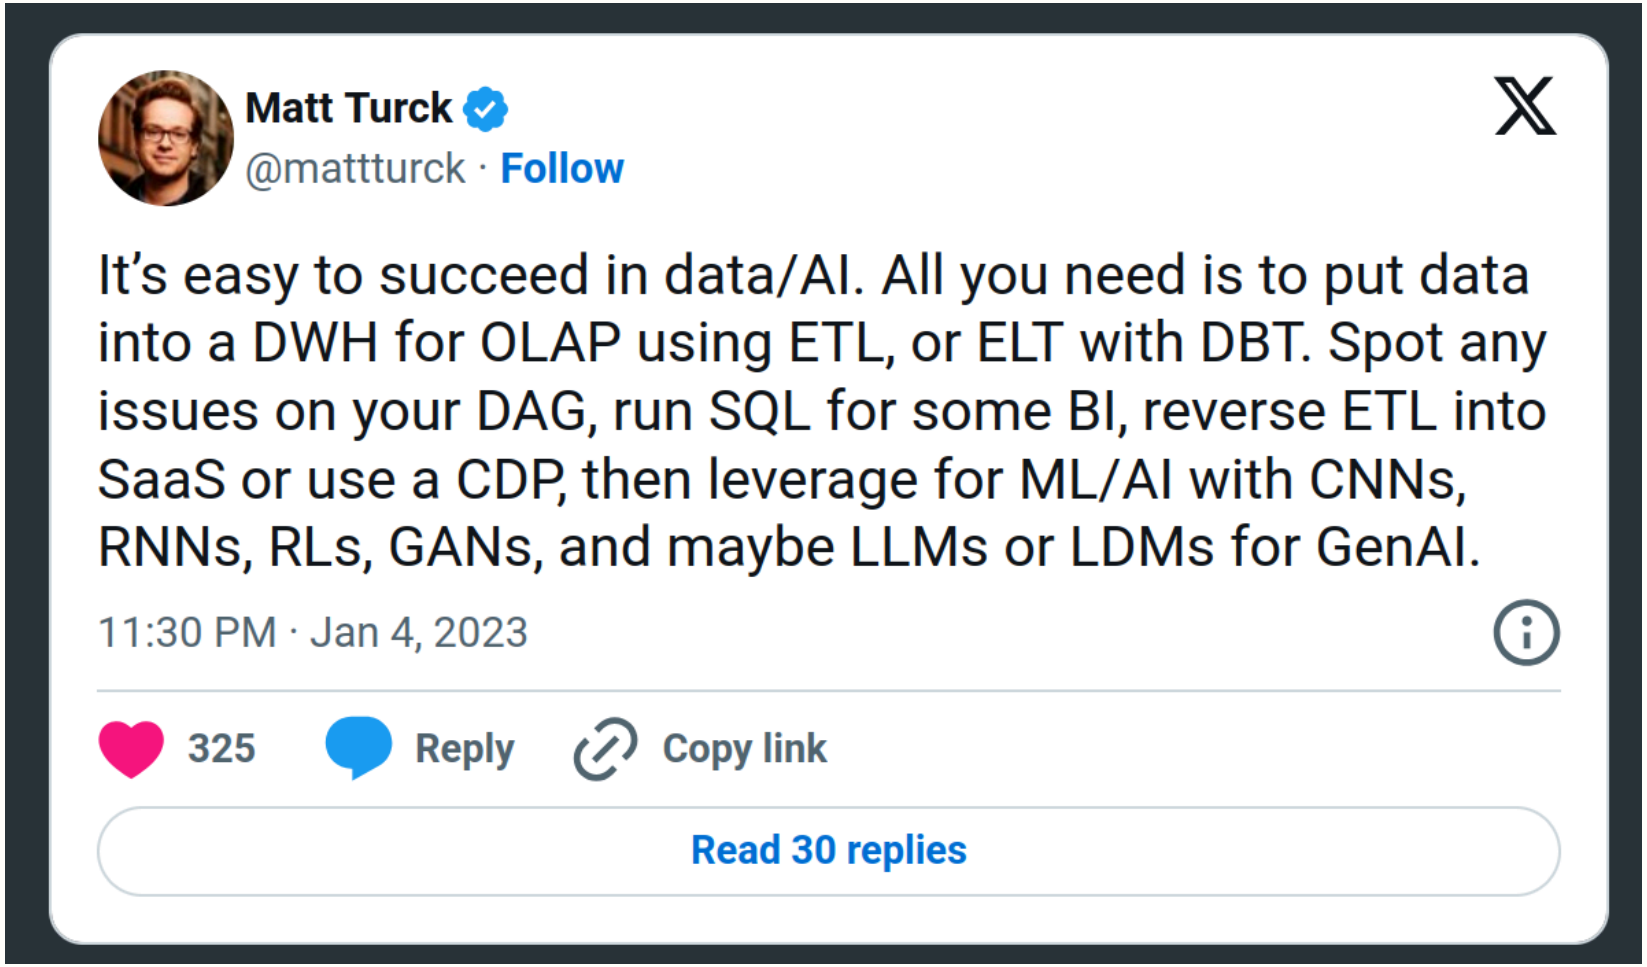


¿Cuándo introdujo Apple «Swift»?

Una mirada al tag `swift` de todas las preguntas de Stack Overflow



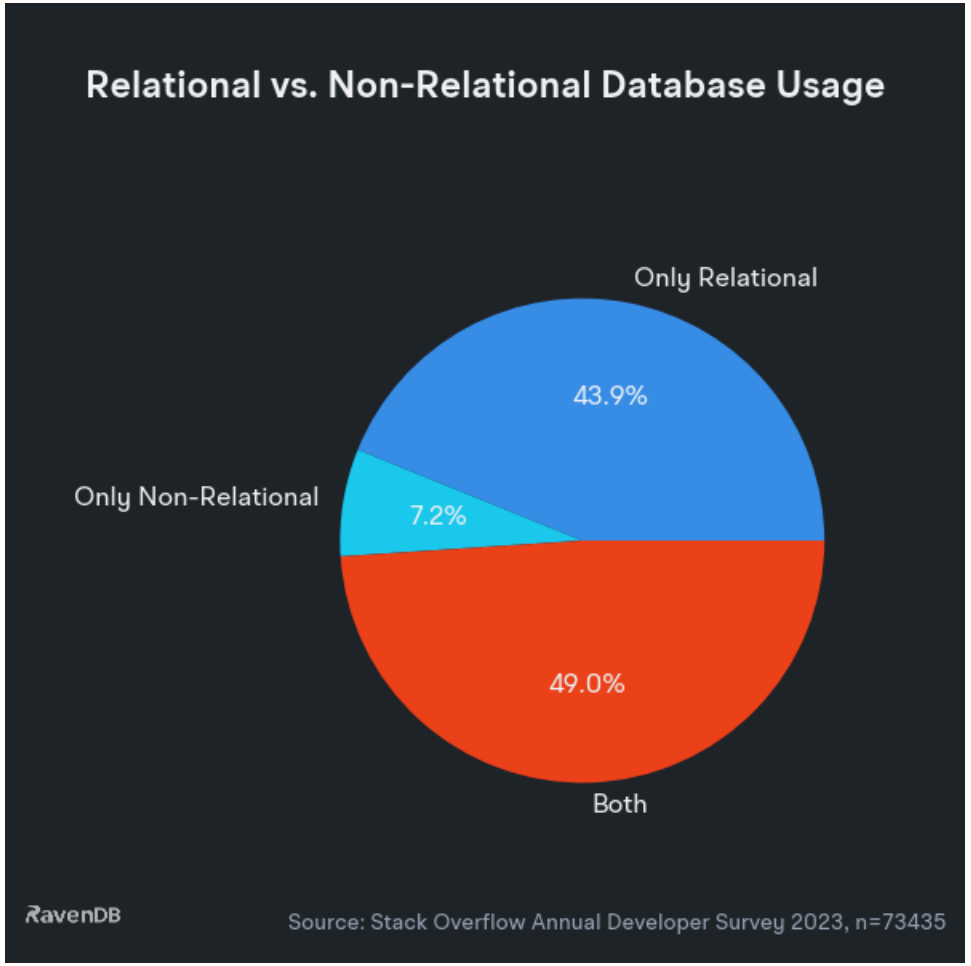
¿Bases de datos hoy?



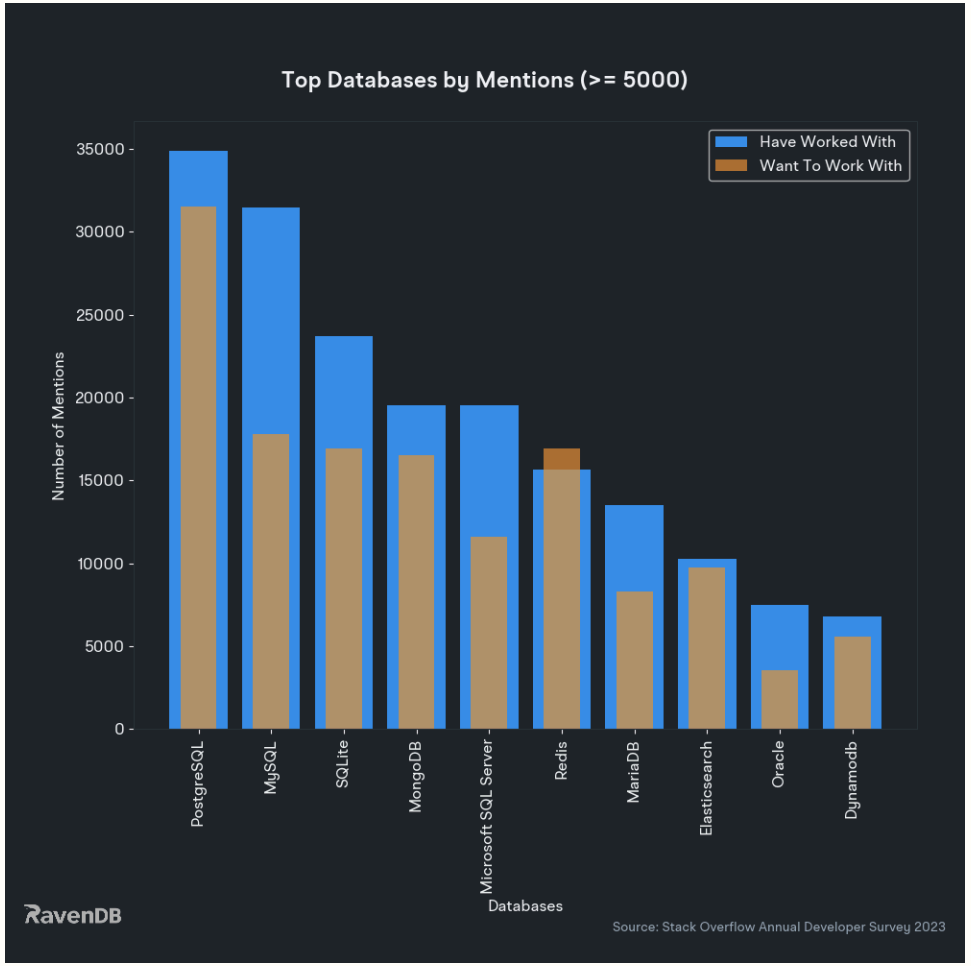
¿Bases de datos hoy?

- No hay fuentes fiables que muestren el uso real de las bases de datos
- Referencias útiles:
  - DB-Engines Ranking
  - 2024 NoSQL Database Trend Report, basado en el JetBrains 2023 Developer Ecosystem
  - Stack Overflow Developer Survey 2025
  - JetBrains 2024 Developer Ecosystem: Databases
  - Encuesta DeveloperWeek 2019, con más de 8 000 desarrolladores

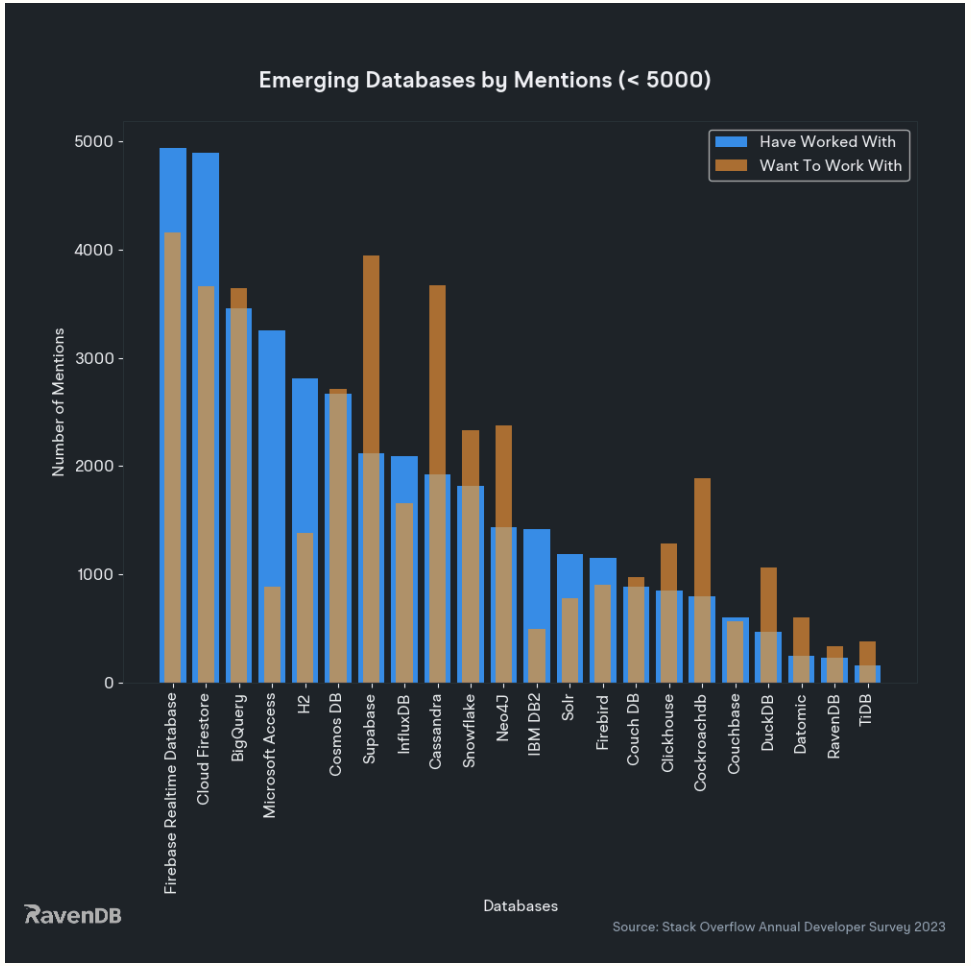
SQL, NoSQL y persistencia políglota



Bases de datos más populares

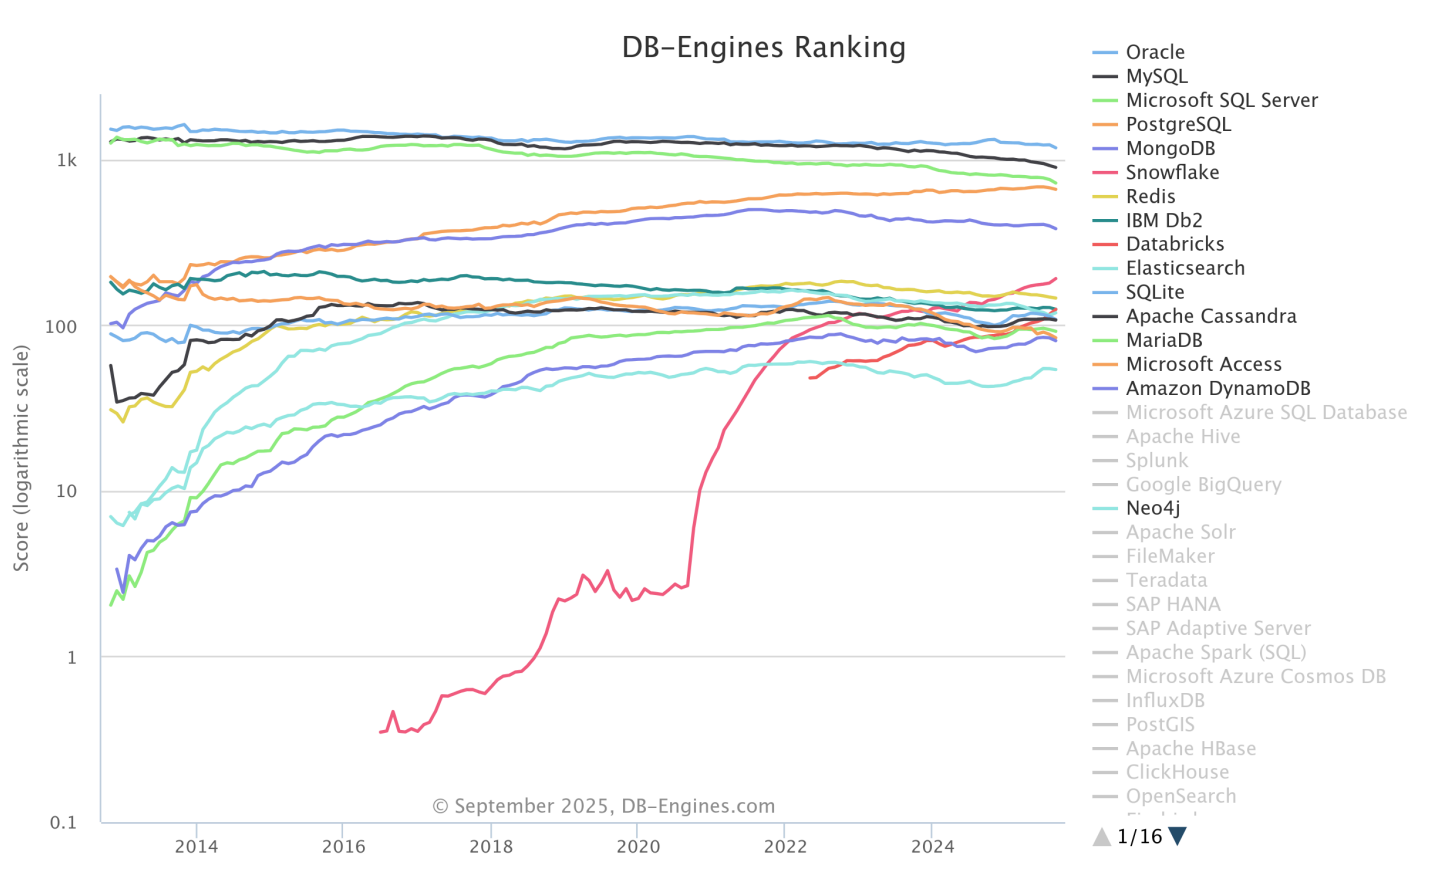


Bases de datos emergentes



Comparación con DB-Engines

https://db-engines.com/en/ranking



Bases de datos usadas en el último año

JetBrains, 2024



	2019	2020	2021	2022	2023	2024
MySQL	60%	59%	61%	52%	51%	52%
PostgreSQL	32%	35%	36%	38%	38%	45%
MongoDB	30%	32%	28%	27%	27%	30%
SQLite	29%	27%	29%	28%	25%	30%
Redis	27%	25%	29%	27%	26%	29%
Microsoft SQL Server	22%	20%	19%	18%	18%	20%
MariaDB	21%	19%	23%	18%	16%	16%
Elasticsearch	–	–	–	–	–	13%
Oracle Database	16%	14%	13%	11%	13%	12%
Amazon DynamoDB	–	–	–	–	–	10%
H2	7%	6%	5%	6%	6%	6%
BigQuery	–	–	–	–	–	5%
Cloud Firestore	–	–	–	–	–	5%
Amazon Athena	–	–	–	–	–	3%
ClickHouse	1%	1%	2%	2%	3%	3%
Snowflake	–	–	–	–	–	3%
Amazon Redshift	5%	4%	3%	3%	4%	3%
Cassandra	4%	3%	3%	3%	3%	3%
Db2	3%	3%	2%	2%	3%	2%
Neo4j	2%	2%	2%	2%	2%	2%
HBase	3%	2%	2%	1%	1%	2%
CockroachDB	–	–	–	–	–	1%
Couchbase	1%	1%	1%	1%	1%	1%
Presto	–	–	–	–	–	1%
Other	7%	7%	7%	8%	7%	4%
None	7%	8%	8%	9%	11%	8%

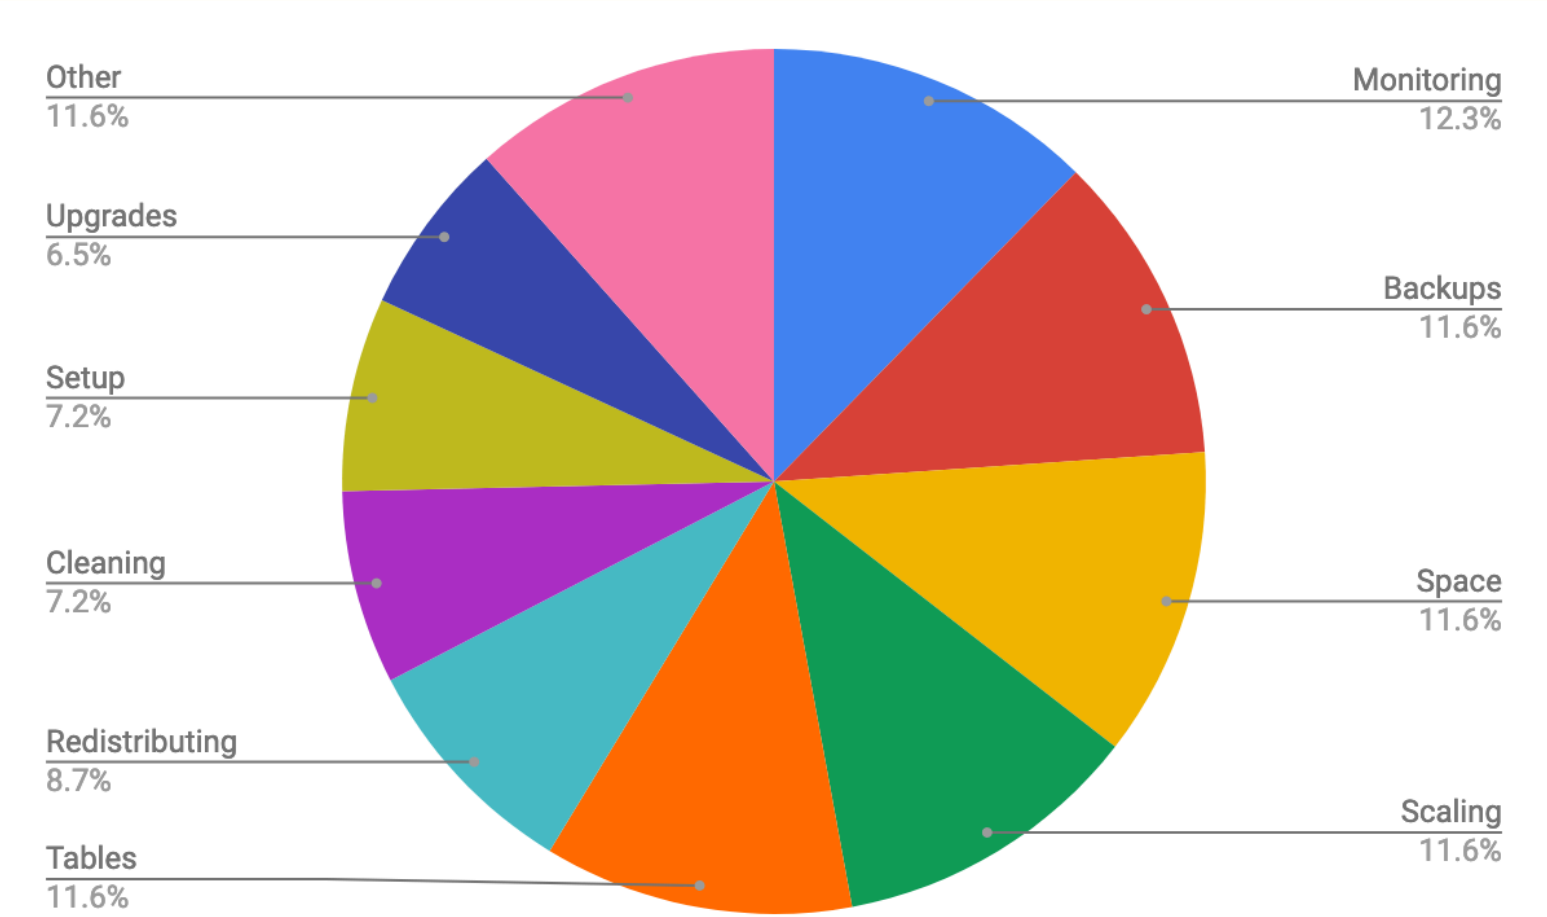
Reciprocidad entre bases de datos

Alta en combinaciones SQL + NoSQL

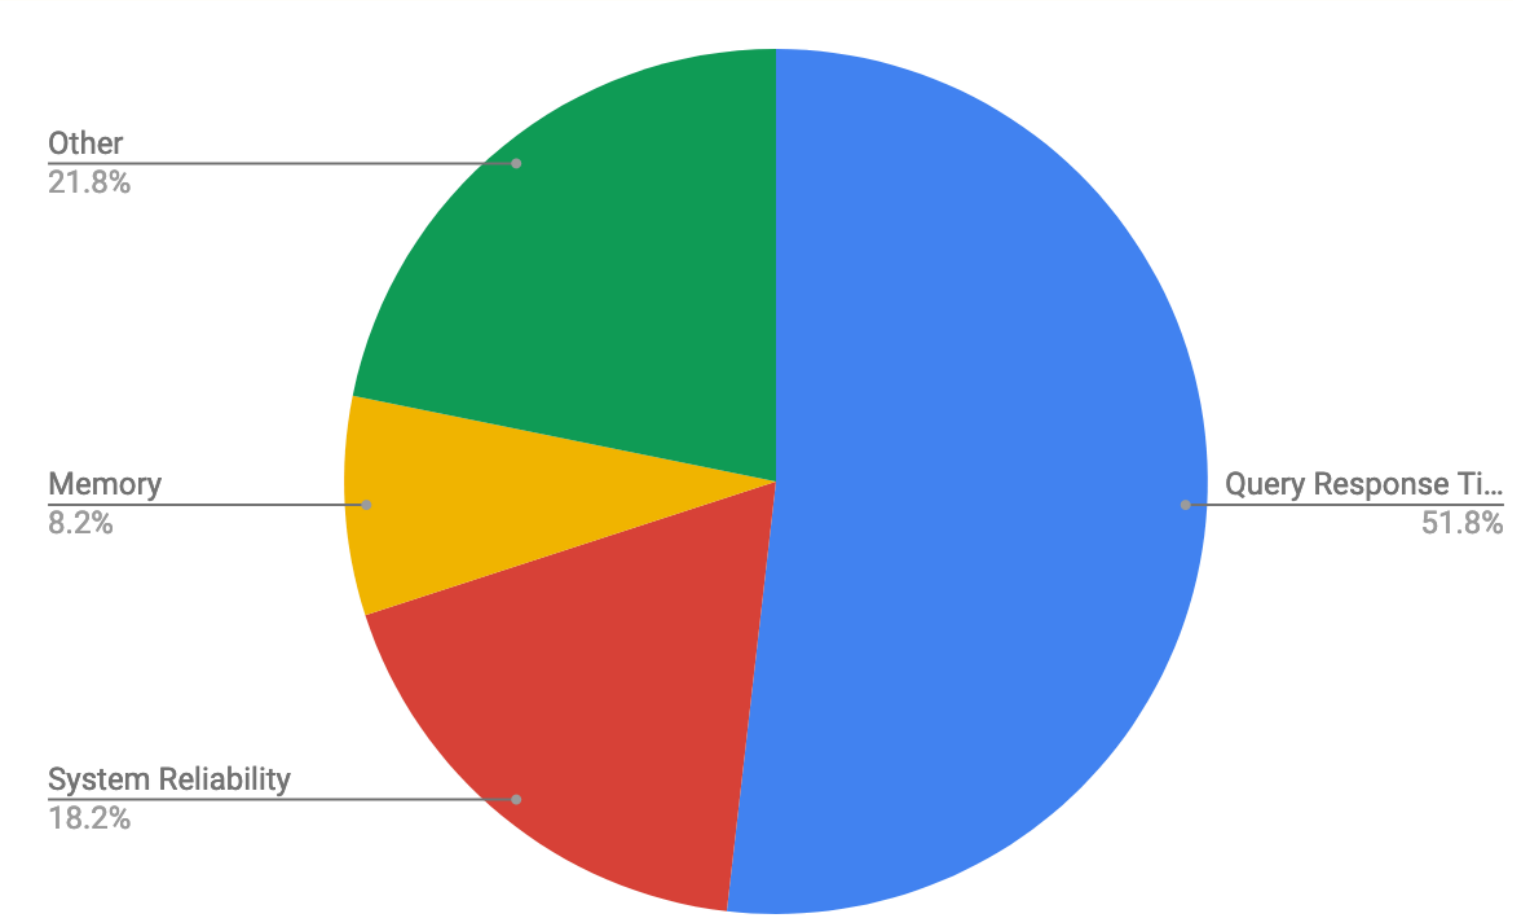
	MySQL	PostgreSQL	MongoDB	Redis	SQLite	MS SQL Server	MariaDB	Oracle Database
MySQL	–	51%	64%	69%	59%	53%	75%	58%
PostgreSQL	38%	–	50%	55%	51%	39%	50%	40%
MongoDB	33%	35%	–	40%	32%	31%	37%	29%
Redis	35%	37%	39%	–	34%	22%	38%	29%
SQLite	29%	33%	30%	32%	–	28%	38%	21%
MS SQL Server	18%	18%	21%	15%	20%	–	20%	29%
MariaDB	23%	20%	22%	23%	24%	18%	–	16%
Oracle Database	14%	13%	14%	14%	11%	21%	13%	–
DB2	3%	3%	3%	3%	2%	4%	3%	6%
Cassandra	3%	4%	5%	5%	2%	3%	3%	4%
Couchbase	1%	1%	1%	1%	1%	1%	1%	2%
HBase	2%	2%	2%	4%	2%	2%	2%	3%
Neo4j	3%	3%	4%	4%	3%	2%	3%	3%
Amazon Redshift	3%	5%	5%	4%	3%	5%	4%	6%
H2	7%	9%	8%	9%	6%	6%	10%	12%
ClickHouse	3%	4%	3%	6%	2%	2%	3%	3%
Other	5%	8%	6%	7%	6%	7%	6%	6%

0 75%

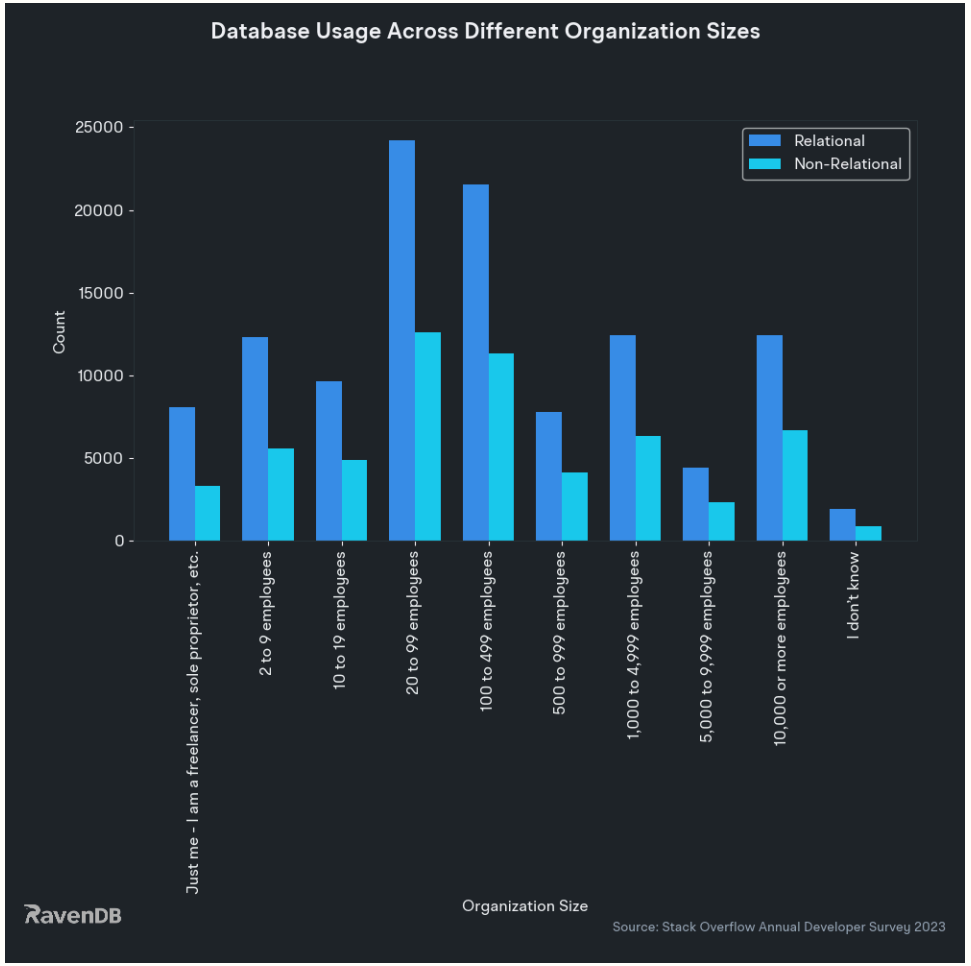
Tareas que más consumen tiempo



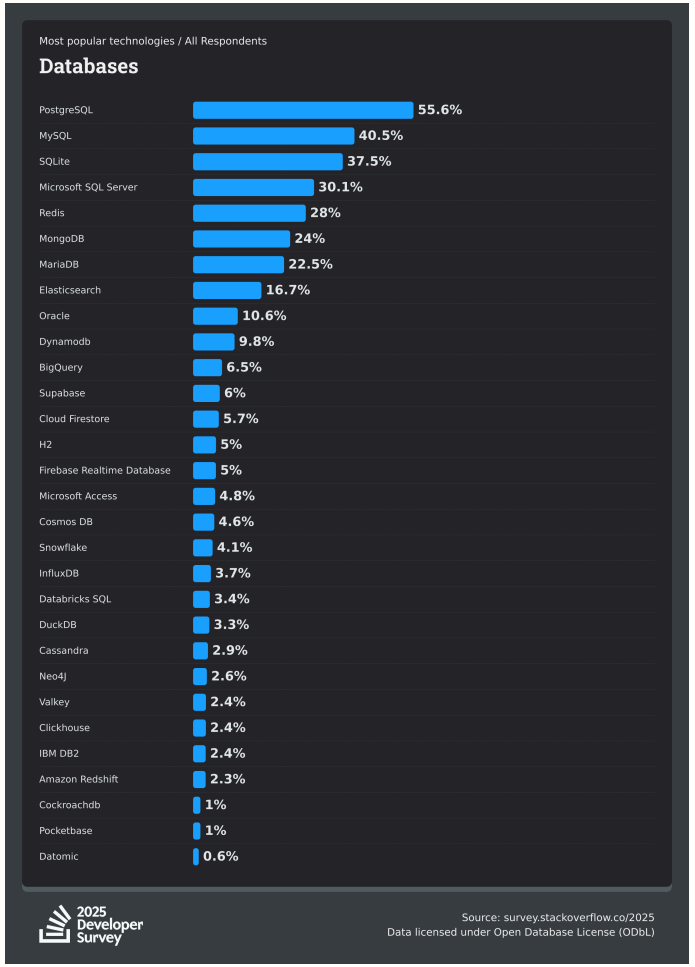
Métricas más importantes en bases de datos



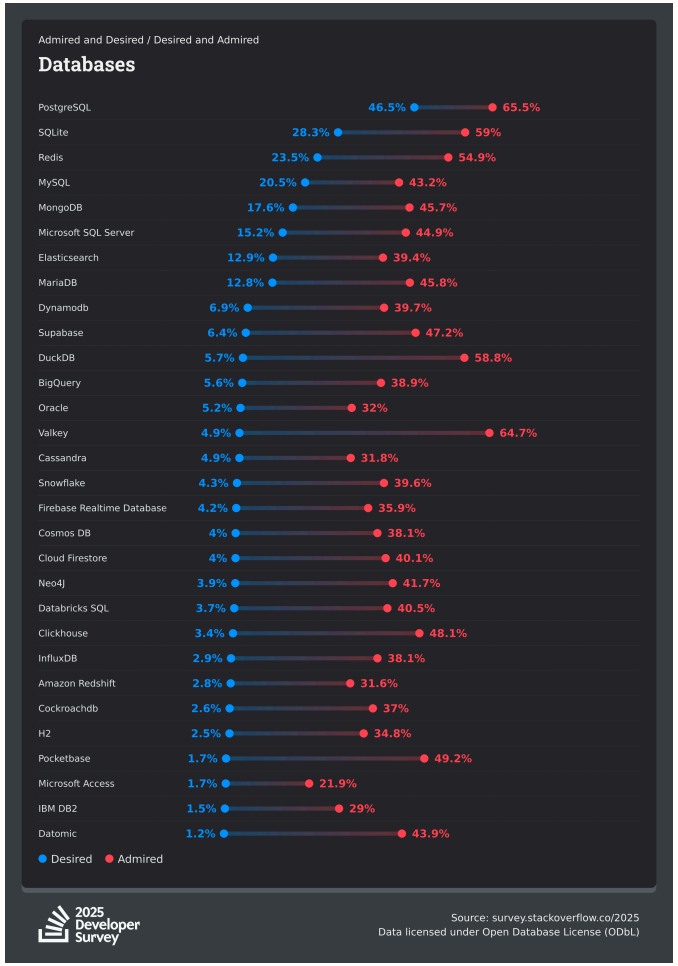
Uso de bases de datos según el tamaño de la empresa



Stack Overflow: uso de bases de datos



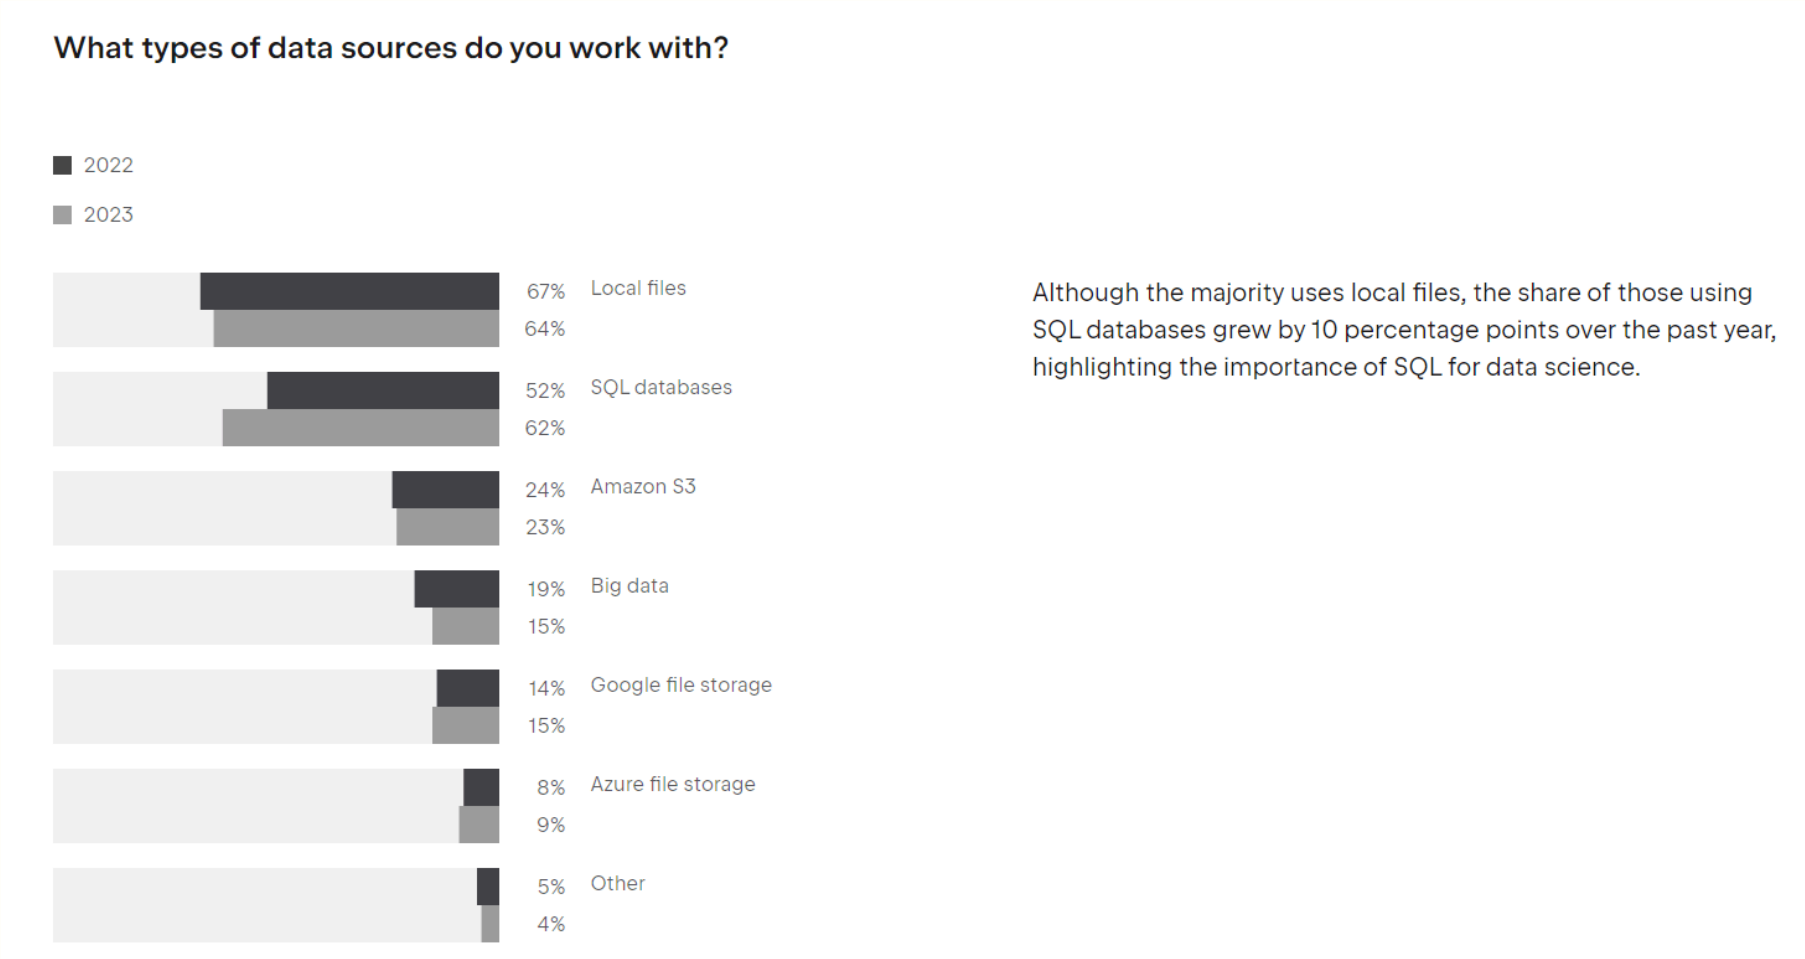
Stack Overflow: bases de datos queridas y admiradas



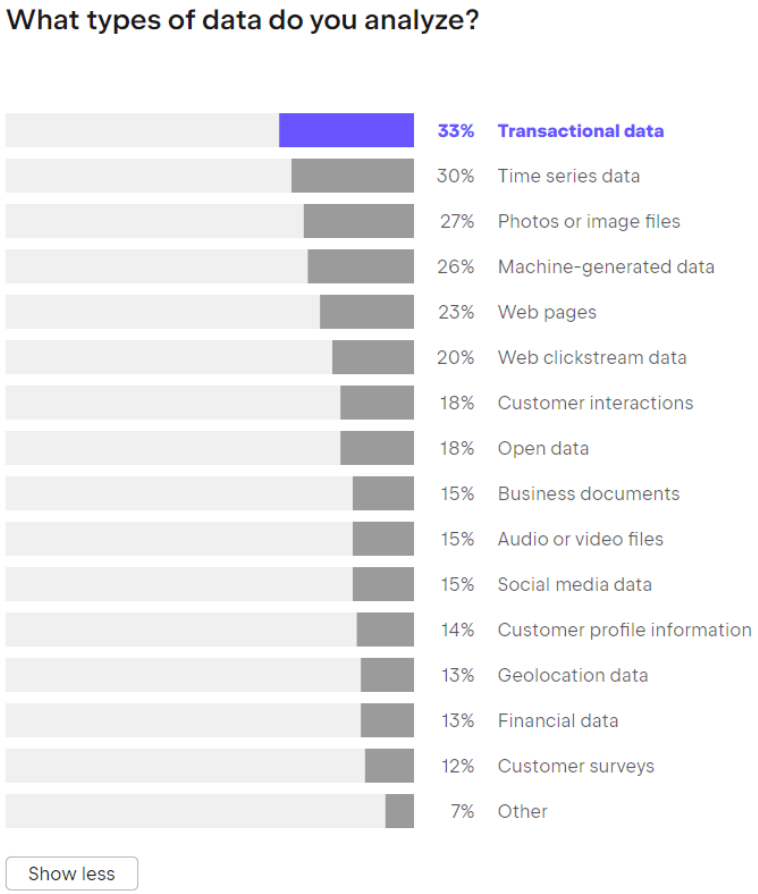
Resumen

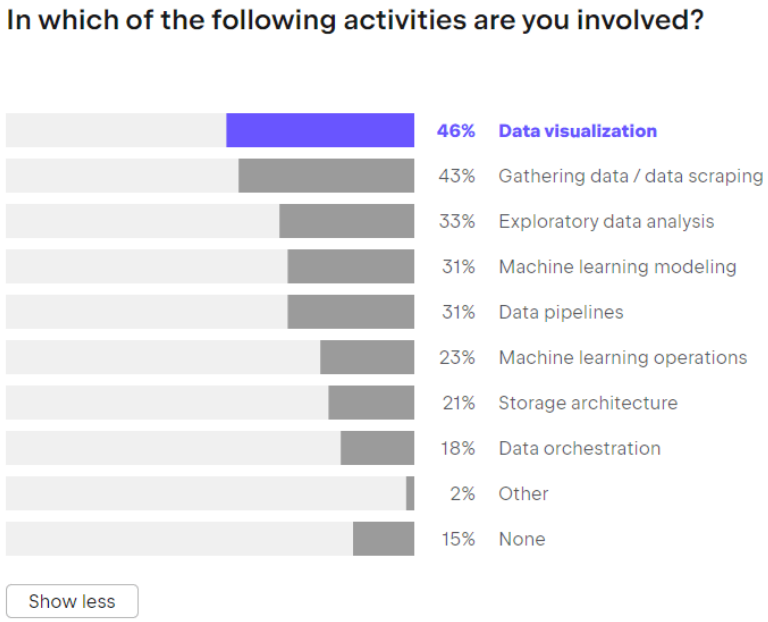
- Las bases de datos relacionales no van a desaparecer, aunque no sean las favoritas de los desarrolladores: casi la mitad combina SGBDR y NoSQL
- NoSQL se adopta para roles especializados: Redis y MongoDB muestran una alta reciprocidad con las bases de datos relacionales
- La IA y el *machine learning* impulsarán la demanda de datos
- Aumentan las nubes especializadas y los datos gestionados
- NoSQL se usará cada vez más con sistemas distribuidos

Fuentes de datos para proceso



Tipos de proceso de datos





Planificación del curso

Fecha	Sesión de teoría	Sesión de prácticas
23/09	Introducción a la asignatura (teo y pr.)	-- (festivo, apertura curso)
30/09 y 01/10	Introducción al modelado de datos, SQL (T1)	Prácticas de SQL (P1)
07 y 08/10	SQL (II) (T2)	Prácticas de SQL (II) (P2*)
Semana 12/10	--	-- (cambio por IN)
21 y 22/10	Introducción a los sistemas NoSQL (T3)	Bases de datos de documentos (T4)
28 y 29/10	Bases de datos de documentos (P3)	Bases de datos de documentos (P4*)
04 y 05/11	Bases de datos columnares (T5)	Bases de datos columnares (P5)
11 y 12/11	Bases de datos columnares (II)	Bases de datos columnares (P6*)
18 y 19/11	Bases de datos de grafos (T6)	Práctica de bases de datos de grafos (P7*)
26/11	--	Repaso/Pruebas parciales
03/12	--	Repaso/Pruebas parciales

`P2*`, `P4*`, `P6*` y `P7*` son los boletines con entrega; el resto son prácticas guiadas

Calendario de las sesiones

```
SEPTIEMBRE 2026                 CONTENIDO DE LA SEMANA
Lu Ma Mi Ju Vi Sá Do
21 22 23 24 25 26 27              23/09  Introducción a la asignatura
28 29 30                        30/09–01/10  T1/P1 · Modelado de datos y SQL

OCTUBRE 2026
Lu Ma Mi Ju Vi Sá Do
          1  2  3  4
 5  6  7  8  9 10 11              07–08/10  T2/P2 · SQL (II): DDL
12 13 14 15 16 17 18              12/10  (sin clase; cambio por IN)
19 20 21 22 23 24 25              21–22/10  T3/T4 · NoSQL y documentos
26 27 28 29 30 31                 28–29/10  P3/P4 · MongoDB

NOVIEMBRE 2026
Lu Ma Mi Ju Vi Sá Do
                   1
 2  3  4  5  6  7  8              04–05/11  T5/P5 · Cassandra
 9 10 11 12 13 14 15              11–12/11  T5 (II)/P6 · Cassandra
16 17 18 19 20 21 22              18–19/11  T6/P7 · Grafos y Neo4j
23 24 25 26 27 28 29              26/11  Repaso y pruebas parciales
30

DICIEMBRE 2026
Lu Ma Mi Ju Vi Sá Do
    1  2  3  4  5  6              03/12  Repaso y pruebas parciales
```

Estructura de todos los boletines de prácticas

- **Ejercicios numerados** con una celda vacía a continuación para escribir la solución y una comprobación automática (`assert`) justo después de cada uno, para saber al momento si vas bien
- **Guía de estudio para el examen**: cada boletín termina con una lista de cuestiones importantes que debes saber hacer sin la IA delante
- Sirven como **guía de práctica** (aprendes haciendo), **guía de estudio** (repasas antes del examen) e **instrumento de autoevaluación** (los `assert` te dicen si lo has entendido)
- Los boletines marcados con `*` en el cronograma son **evaluables**: se califican y cuentan hacia la nota final

Sistema de evaluación de los boletines evaluables

- **Identificador personal**: al principio de cada boletín evaluable, declares tu DNI
- **Parámetros personalizados**: los umbrales, años y actividad mínima de cada ejercicio salen de tu identificador; cada alumno resuelve una variante distinta
- **Entrega única**: una celda final con una única consulta pequeña y determinista que, al ejecutarse, envía un «indicio» de ejecución a un servidor de evidencias
- **Acuse de recibo**: el servidor devuelve un ID que identifica de forma única tu entrega; puedes comprobarlo en cualquier momento

Evaluación

- Trabajos: **20 %** (opcional)
  - Propuestos por el profesor o el alumnado
  - Estudio de alguna publicación relevante y entrega de trabajo
- Prácticas de la asignatura: **30 %**
- Pruebas periódicas, **examen final** o trabajo final: **50 %**

Dentro de ese 30 % de prácticas

- **15 % la entrega de los boletines evaluables**, con el envío automático que acabamos de ver
- **15 % la parte práctica de la prueba final**: modelar, escribir una consulta, interpretar un plan o reparar una solución
- La prueba final es **teórico-práctica**, y el reparto global de la guía no cambia
- **No hay nota mínima por parte**: se aprueba con **5 sobre 10** en la suma ponderada
- No presentar las prácticas o la prueba final supone **«No presentado»**

> El boletín no es la prueba de que has aprendido: es la preparación para demostrarlo

Prácticas interactivas en el navegador

En el sitio web de la asignatura, sección **Prácticas interactivas**, hay páginas de prueba con consultas para cada sistema, **sin instalar nada**:

Sistema	Sesiones	Motor en el navegador	Qué se practica
SQL	1 y 2	DuckDB-Wasm	Consultas, CTE, funciones ventana, JSON y `EXPLAIN`
MongoDB	3 y 4	mingo (sintaxis PyMongo)	Consultas, actualización y agregación
Cassandra	5 y 6	Simulador de CQL	Particionado, clustering y optimización de consultas
Neo4j	7	Ladybug (Cypher)	Patrones, recorridos y modelado, con el grafo dibujado

Prácticas interactivas: cómo usarlas

- Los datos son los de Stack Overflow en español; en Cassandra, un conjunto sintético pequeño
- Cada ejercicio permite **comprobar** tu resultado contra el de referencia
- El motor del navegador **no es exactamente el de los boletines** (MySQL 8, MongoDB, Cassandra, Neo4j): en Cassandra es un simulador de un subconjunto de CQL, y lo que depende del producto, como `EXPLAIN ANALYZE` o APOC, sigue necesitando el boletín en Colab/Jupyter
- Sirven para practicar en cada base de datos

Bibliografía

- Nathan Marz y James Warren. **Big Data: Principles and Best Practices of Scalable Realtime Data Systems**, Manning, 2015
- Eric Redmond y Jim R. Wilson. **Seven Databases in Seven Weeks: A Guide to Modern Databases and the NoSQL Movement**, Pragmatic Bookshelf, 2012
- Pramod J. Sadalage y Martin Fowler. **NoSQL Distilled: A Brief Guide to the Emerging World of Polyglot Persistence**, Addison-Wesley, 2013

Repositorio de la asignatura

- Guiones de prácticas e información adicional
- Repositorio público: https://github.com/dsevilla/bdge
- Sitio web de la asignatura: dsevilla.github.io/bdge
- Rama del curso: `26-27`

```
$ git clone --depth 1 -b 26-27 https://github.com/dsevilla/bdge.git
$ cd bdge
```

La copia contiene todos los archivos actuales de `26-27`, sin descargar el historial anterior

No hace falta clonarlo para las prácticas: usaremos **Google Colab**; para ejecutarlas en local con Docker o Podman, ver las últimas diapositivas

Google Colab

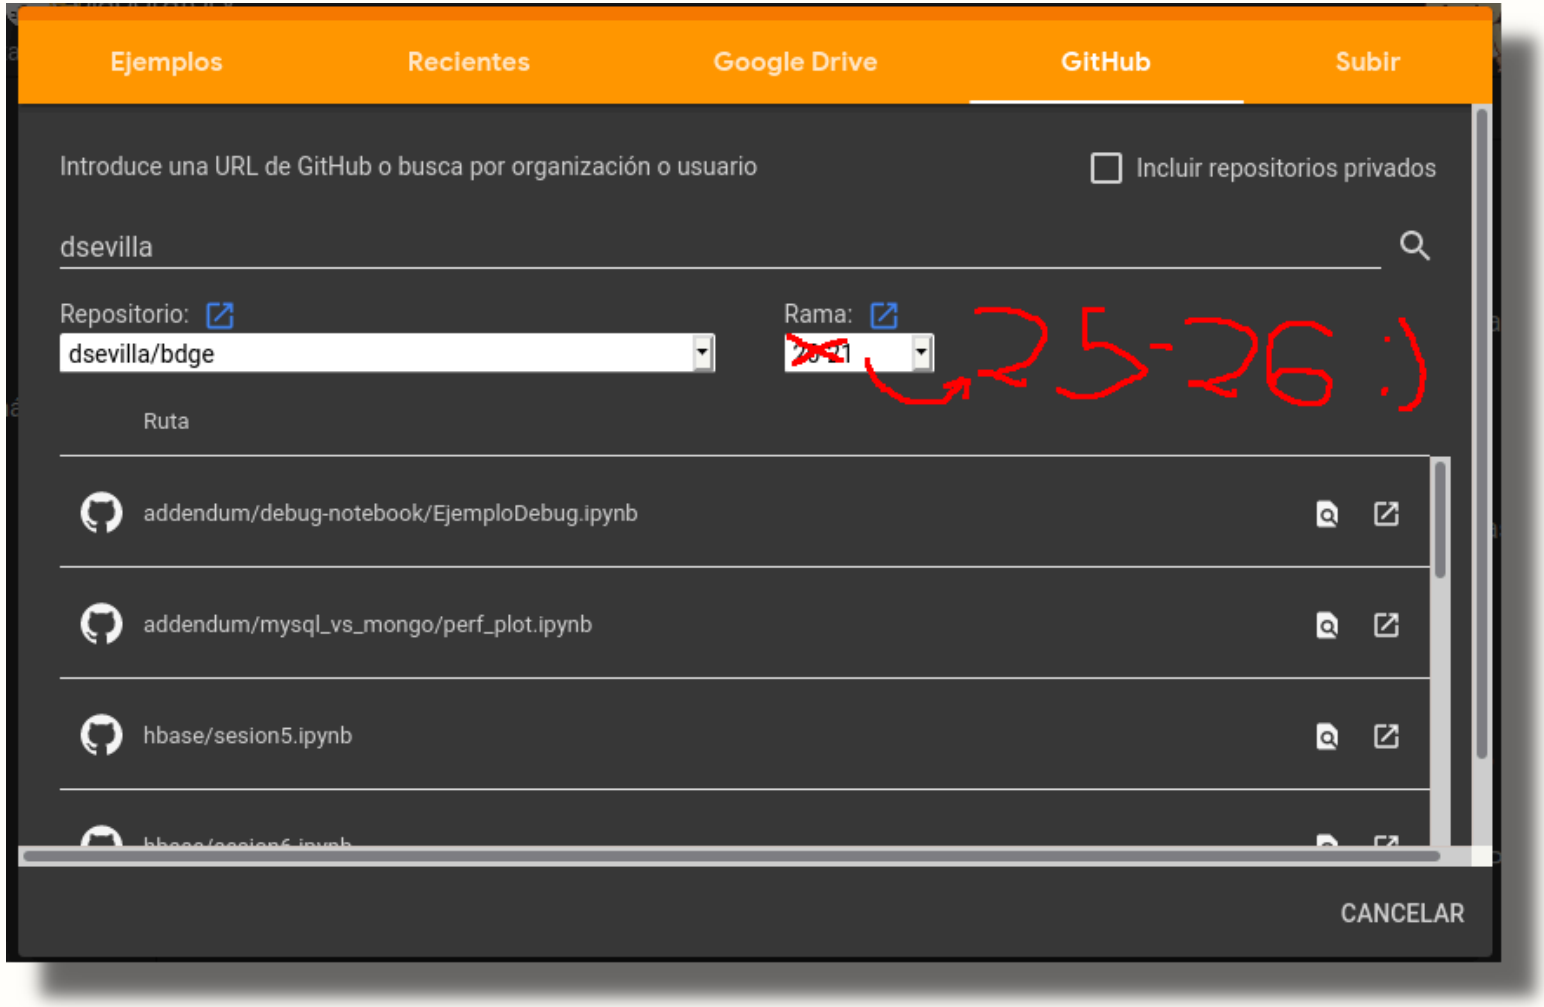
https://colab.research.google.com/



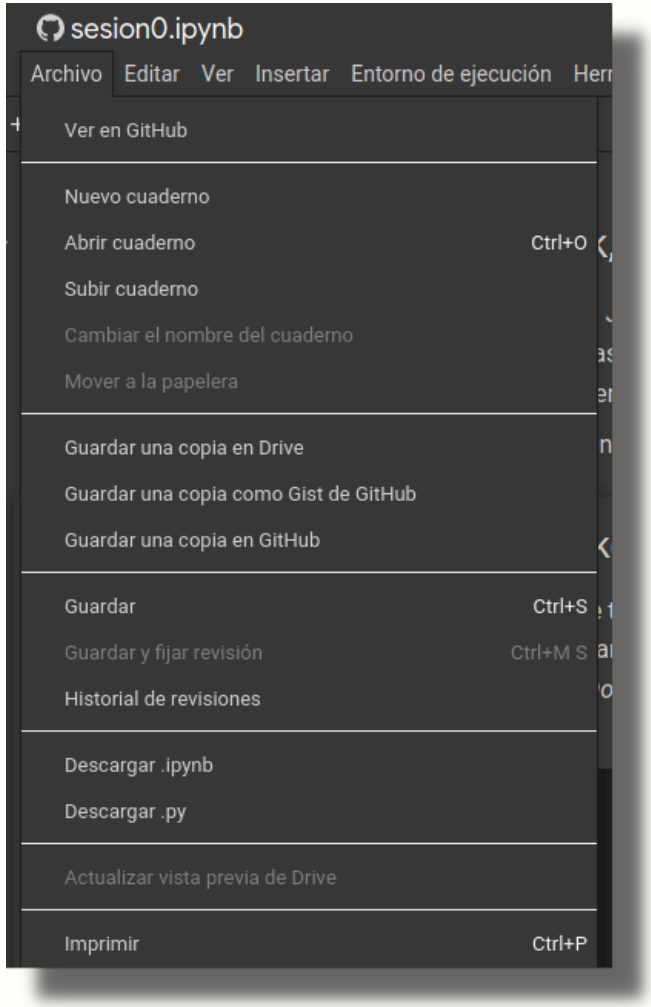
Google Colab

- En **Archivo** → **Abrir cuaderno**, seleccionar **GitHub**
  - Habrá que dar permiso de acceso; pueden limitarse a repositorios públicos
- En el primer cuadro de texto: **dsevilla**
- Repositorio: **dsevilla/bdge**; rama: **26-27**
- Las sesiones están en subdirectorios; por ejemplo, `intro/sesion0.ipynb`
- Al terminar, usar **Archivo** → **Guardar cuaderno** en:
  - **Drive**, o
  - **GitHub** (en un repositorio propio, que puede ser privado)

Google Colab



Google Colab



Ejecutar los notebooks en local: Docker

Cada directorio de sesiones (`intro`, `sql`, `mongo`, `cassandra`, `neo4j`) trae un `docker-compose.yml` que levanta **Jupyter** y, salvo en `intro`, la **base de datos** del tema

```
$ git clone --depth 1 -b 26-27 https://github.com/dsevilla/bdge.git
$ cd bdge/sql              # igual para intro, mongo, cassandra, neo4j...
$ docker compose up
```

- Jupyter en http://localhost:8888 (token `bdge`); lo que se guarda queda en el repositorio local
- `Ctrl+C` para parar; `docker compose down` elimina los contenedores
- En `cassandra`, añadir `-f docker-compose-cassandra.yml`

Ejecutar los notebooks en local: Podman

Podman ejecuta los mismos ficheros sin privilegios (*rootless*), con un segundo fichero, `docker-compose.podman.yml`, que hace que tu usuario aparezca en el contenedor como el de Jupyter (`keep-id`); sin él, Jupyter no puede guardar en el repositorio

```
$ cd sql                    # igual para intro, mongo, neo4j...
$ podman compose -f docker-compose.yml -f docker-compose.podman.yml up
```

- Jupyter, el token y `podman compose down`, como con Docker
- En `cassandra`: `docker-compose-cassandra.yml` y `docker-compose-cassandra.podman.yml`
- `podman compose` necesita `docker-compose` o `podman-compose` instalado

Podman: preparación, una sola vez

Activar el socket de Podman para tu usuario, y decirle dónde buscar las imágenes con nombre corto (`mysql:8`, `mongo:9.0`…):

```
$ systemctl --user enable --now podman.socket
$ mkdir -p ~/.config/containers/registries.conf.d
$ nano ~/.config/containers/registries.conf.d/10-docker-hub.conf
```

Contenido del fichero:

```
unqualified-search-registries = ["docker.io"]
```

Cassandra: uno o dos nodos

- `docker-compose-cassandra.yml`: **un nodo**, la más ligera y la habitual
- `docker-compose-cassandra-2.yml`: **dos nodos** (`cassandra1`, `cassandra2`) en la misma red: un clúster pequeño con replicación; más memoria (4 GB de *heap* por nodo) y arranque más lento (hasta un par de minutos)
- Con dos nodos, el notebook corre en el contenedor `notebook` de esa red; desde el equipo sólo va `cqlsh` (puertos 9042 y 9043): cada nodo publica su dirección **dentro** de la red de Docker

```
$ cd cassandra
$ docker compose -f docker-compose-cassandra-2.yml up
$ podman compose \
    -f docker-compose-cassandra-2.yml \
    -f docker-compose-cassandra.podman.yml up
```